

FIAP - Faculdade de Informática e Administração Paulista
Pós-graduação em Inteligência Artificial para Desenvolvedores

Gustavo Feikes Marino de Siqueira

CLASSIFICAÇÃO DE TUMORES DE MAMA COM MACHINE LEARNING

Um sistema de apoio ao diagnóstico avaliado pelo custo clínico do erro

Relatório técnico apresentado como requisito de avaliação do Tech Challenge da Fase 1 do curso de Pós-graduação em Inteligência Artificial para Desenvolvedores da FIAP.

RESUMO

Este relatório apresenta um sistema de apoio ao diagnóstico de câncer de mama construído sobre a base Breast Cancer Wisconsin (Diagnostic), com 569 amostras e 30 medidas morfológicas de núcleos celulares. Foram comparadas três técnicas de classificação, Regressão Logística, KNN e Random Forest, por validação cruzada estratificada de cinco partições dentro do conjunto de treino. A Regressão Logística obteve o melhor desempenho e alcançou, no conjunto de teste de 114 casos, acurácia de 0,965, recall de 0,929 na classe maligna, F1 de 0,951 e AUC de 0,996, com três falsos negativos. A métrica prioritária adotada é o recall da classe maligna, porque o custo clínico de um falso negativo é muito superior ao de um falso positivo. A redução do limiar de decisão de 0,50 para 0,30 diminui os falsos negativos de três para um sem aumentar os falsos positivos. A interpretação dos resultados combina coeficientes do modelo linear, importância por permutação e valores SHAP, que convergem nas mesmas medidas. Como entrega complementar, o mesmo problema foi tratado a partir de imagens de ultrassom da base BUSI, em que uma rede MobileNetV2 com ajuste fino alcançou recall de 0,900 na classe maligna, com explicabilidade por Grad-CAM. Conclui-se que o sistema é adequado ao uso como ferramenta de triagem e segunda opinião, jamais como decisor autônomo.

Palavras-chave: aprendizado de máquina; câncer de mama; apoio ao diagnóstico; explicabilidade; redes neurais convolucionais.

SUMÁRIO

RESUMO	2
1 INTRODUÇÃO	4
2 ANÁLISE EXPLORATÓRIA	4
2.1 Qualidade e distribuição das classes	4
2.2 Padrões relacionados ao diagnóstico	5
3 PRÉ-PROCESSAMENTO	6
3.1 Limpeza e conversão de variáveis	6
3.2 Pipeline de pré-processamento	6
3.3 Análise de correlação	7
3.4 Separação entre treino e teste	7

4	MODELAGEM	8
4.1	Modelos selecionados	8
4.2	Escolha da métrica	8
4.3	Validação cruzada no conjunto de treino	8
5	RESULTADOS	9
5.1	Desempenho no conjunto de teste	9
5.2	Ajuste do limiar de decisão	10
6	EXPLICABILIDADE	11
7	DISCUSSÃO CRÍTICA	14
7.1	O modelo pode ser usado na prática?	14
7.2	Cenários de uso e riscos de implantação	14
8	ENTREGA COMPLEMENTAR: DIAGNÓSTICO POR IMAGEM	15
9	REPRODUTIBILIDADE E EXECUÇÃO	16
10	CONSIDERAÇÕES FINAIS	17
	REFERÊNCIAS	18
	APÊNDICE A – RASTREABILIDADE DAS EXIGÊNCIAS DO DESAFIO	19

1 INTRODUÇÃO

Uma rede de hospitais e centros de saúde especializados no atendimento à mulher precisa acelerar a triagem diante de um volume crescente de pacientes. Este trabalho entrega a base de aprendizado de máquina dessa solução: a classificação automática de tumores de mama em malignos ou benignos.

A base utilizada é a Breast Cancer Wisconsin (Diagnostic), com 569 amostras e 30 características numéricas, todas com diagnóstico confirmado. Ela está disponível publicamente e é versionada no repositório do projeto em `data/raw/data.csv`.

As 30 features correspondem a 10 medidas do núcleo celular, obtidas de imagens de punção aspirativa por agulha fina: raio, textura, perímetro, área, suavidade, compacidade, concavidade, pontos côncavos, simetria e dimensão fractal. Cada medida aparece em três variantes, a média da amostra (`_mean`), o erro padrão (`_se`) e a média das três piores células observadas (`_worst`).

Uma premissa orienta todas as decisões técnicas do trabalho: o modelo é ferramenta de triagem e de segunda opinião, e o diagnóstico final permanece sob responsabilidade do médico. Dela decorrem a escolha da métrica prioritária e a exigência de explicabilidade das previsões.

O código-fonte, os notebooks executados e o relatório visual estão no repositório <https://github.com/gustavofks/ML-breast-cancer>. O detalhamento completo da análise, com todas as figuras e a discussão estendida, está no arquivo `docs/relatorio_tecnico.md`.

2 ANÁLISE EXPLORATÓRIA

2.1 Qualidade e distribuição das classes


A base tem 569 registros e nenhum valor ausente real. A única inconsistência encontrada é estrutural: o cabeçalho do arquivo CSV termina em vírgula, o que leva o pandas a criar uma coluna adicional `Unnamed: 32` inteiramente nula. Trata-se de artefato do arquivo, e não de dado faltante, razão pela qual a coluna é descartada no carregamento.

Tabela 1 - Distribuição das classes na base completa

Classe	Amostras	Proporção
Benigno	357	62,7%
Maligno	212	37,3%

Fonte: elaborado pelo autor.

Figura 1 - Distribuição dos diagnósticos na base



Fonte: elaborado pelo autor.

O desbalanceamento é leve, mas produz duas consequências que atravessam todo o projeto. A primeira é que a acurácia isolada engana, pois um classificador que respondesse sempre "benigno" já atingiria 62,7% de acerto. A segunda é que a divisão entre treino e teste precisa ser estratificada para permanecer representativa.

As escalas das features variam em até cinco ordens de grandeza, com `area_worst` na casa dos milhares e `fractal_dimension_se` na casa dos centésimos, o que torna a padronização obrigatória. Diversas features apresentam assimetria à direita, comportamento esperado em medidas biológicas de tamanho e irregularidade.

2.2 Padrões relacionados ao diagnóstico

O *d* de Cohen mede a distância entre as médias das duas classes em unidades de desvio padrão. Por ser adimensional, permite comparar features de escalas distintas.

Tabela 2 - Features com maior poder de separação entre as classes

Feature	Média benigno	Média maligno	d de Cohen
concave points_worst	0,0744	0,1822	2,69
perimeter_worst	87,01	141,37	2,60
concave points_mean	0,0257	0,0880	2,54
radius_worst	13,38	21,13	2,54

perimeter_mean	78,08	115,37	2,29
----------------	-------	--------	------

Fonte: elaborado pelo autor.

Concavidade e pontos côncavos lideram o ranking. Ambas medem o quanto o contorno do núcleo é irregular e reentrante, assinatura morfológica clássica de células malignas. As medidas de tamanho aparecem em seguida, uma vez que núcleos malignos são maiores. Textura, simetria e dimensão fractal separam mal as classes quando observadas isoladamente.

O grupo `_worst` separa as classes com mais nitidez que o grupo `_mean`, resultado com sentido clínico direto: o que caracteriza a malignidade não é o comportamento médio do tecido, e sim a existência de células com morfologia mais agressiva.

Os valores extremos são numerosos e concentram-se na classe maligna. Não são erros de medição, e sim casos graves reais. Removê-los descartaria justamente as pacientes que o sistema mais precisa identificar, motivo pelo qual nenhum foi excluído.

3 PRÉ-PROCESSAMENTO

3.1 Limpeza e conversão de variáveis

Quadro 3 - Tratamentos aplicados na etapa de limpeza

Problema	Tratamento	Justificativa
Coluna <code>Unnamed: 32</code> , totalmente nula	Removida	Artefato da vírgula final no cabeçalho do CSV
Coluna <code>id</code>	Removida	Identificador do paciente, sem relação causal com o diagnóstico
Alvo <code>diagnosis</code> categórico (M/B)	Codificado como <code>M = 1, B = 0</code>	Maligno é a classe positiva, por ser o evento a detectar
Outliers nas medidas morfológicas	Preservados	São casos malignos extremos reais
Valores ausentes	Nenhum na base	Imputador de mediana mantido no pipeline por robustez

Fonte: elaborado pelo autor.

As 30 features preditoras já são numéricas contínuas e não exigem codificação. A única variável categórica da base é o alvo, convertido para binário na limpeza. O que essas variáveis exigem não é codificação, e sim padronização, em razão da diferença de escala descrita na seção anterior.

3.2 Pipeline de pré-processamento

```
Pipeline
└─ preprocessor
```

```

1 | | SimpleImputer(strategy="median") # defensivo
  | | StandardScaler() # média 0, desvio padrão
  | estimator # modelo da vez

```

A padronização permanece dentro do pipeline por um motivo específico. Se fosse ajustada sobre a base completa antes da separação entre treino e teste, a média e o desvio utilizados na transformação carregariam informação do conjunto de teste, caracterizando vazamento de dados e produzindo métricas otimistas que não se sustentam em produção. Dentro do Pipeline, o escalonador é reajustado a cada partição da validação cruzada, usando apenas os dados de treino daquela partição.

3.3 Análise de correlação

Existem 21 pares de features com correlação superior a 0,9, e os extremos são quase perfeitos: `radius_mean` e `perimeter_mean` atingem 0,998, enquanto `radius_mean` e `area_mean` chegam a 0,987. O resultado não é acaso estatístico, e sim geometria, pois em uma forma aproximadamente circular o perímetro e a área são funções diretas do raio.

Nenhuma feature foi removida. Com 569 amostras e 30 features não há alta dimensionalidade, e a regularização L2 já trata a redundância. A multicolinearidade fica registrada porque afeta a leitura dos coeficientes, conforme discutido na seção 6.

Na correlação com a variável alvo, `concave points_worst` (0,79), `perimeter_worst` (0,78) e `concave points_mean` (0,78) ocupam as primeiras posições, reproduzindo o ranking do d de Cohen. Nenhuma feature isolada se aproxima de correlação unitária, o que indica que a classificação depende da combinação de várias medidas.

3.4 Separação entre treino e teste

Tabela 4 - Composição dos conjuntos após a divisão estratificada

Conjunto	Amostras	Benigno	Maligno	Proporção maligno
Treino	455	285	170	37,4%
Teste	114	72	42	36,8%
Base completa	569	357	212	37,3%

Fonte: elaborado pelo autor.

A divisão adota proporção de 80/20, com estratificação pela variável alvo e semente fixa. O conjunto de teste permanece intocado até a avaliação final, e toda a comparação entre modelos ocorre por validação cruzada dentro do conjunto de treino.

4 MODELAGEM

4.1 Modelos selecionados

Quadro 5 - Técnicas comparadas e justificativa de escolha

Modelo	Como decide	Por que foi incluído
Regressão Logística	combinação linear das features passada por uma função sigmoide	baseline interpretável, essencial em contexto clínico
KNN	classe majoritária entre os k casos mais parecidos	não paramétrico e sensível a escala, evidencia o efeito da padronização
Random Forest	votação de árvores treinadas em amostras diferentes	captura relações não lineares e fornece importância nativa

Fonte: elaborado pelo autor.

Os três modelos são construídos como pipelines completos, o que garante que a padronização seja reajustada dentro de cada partição da validação cruzada.

4.2 Escolha da métrica

Os dois tipos de erro não têm o mesmo custo. Um falso negativo corresponde a um tumor maligno classificado como benigno, o que pode atrasar a investigação ou o encaminhamento adequado. Um falso positivo gera exames adicionais, ansiedade e custo. Como o primeiro é incomparavelmente mais grave, a métrica prioritária adotada é o recall da classe maligna.

Duas ressalvas definem o protocolo. A acurácia é reportada, mas não decide isoladamente, em razão do piso de 62,7% já mencionado. O recall puro também não pode selecionar o modelo, pois premiaria um classificador que atribísse malignidade a quase todos os casos, com recall elevado, precisão baixa e nenhuma utilidade em triagem. A seleção, portanto, utiliza a medida F1, e o recall é otimizado posteriormente pelo ajuste do limiar de decisão.

4.3 Validação cruzada no conjunto de treino

Tabela 6 - Desempenho médio na validação cruzada de cinco partições

Modelo	Acurácia	Precisão	Recall	F1	AUC
--------	----------	----------	--------	----	-----

Regressão Logística	0,974	0,977	0,953	0,964	0,996
KNN	0,965	0,988	0,918	0,951	0,987
Random Forest	0,960	0,958	0,935	0,946	0,988

Fonte: elaborado pelo autor.

A Regressão Logística lidera em F1 e em recall, com desvio baixo entre as partições. O KNN apresenta a maior precisão e o menor recall, ou seja, erra pouco quando afirma malignidade, mas deixa passar mais casos malignos, o que representa a troca errada para este problema.

O fato de um modelo linear superar dois modelos não lineares é informativo. Indica que, após a padronização, as classes são quase linearmente separáveis no espaço das 30 features, resultado coerente com a análise exploratória. O modelo escolhido é a Regressão Logística com $C = 1, 0$.

5 RESULTADOS

5.1 Desempenho no conjunto de teste

Tabela 7 - Desempenho dos três modelos nos 114 casos de teste

Modelo	Acurácia	Precisão	Recall	F1	AUC	Falsos negativos
Regressão Logística	0,965	0,975	0,929	0,951	0,996	3
Random Forest	0,965	1,000	0,905	0,950	0,995	4
KNN	0,939	0,973	0,857	0,911	0,983	6

Fonte: elaborado pelo autor.

O desempenho no teste confirma o observado na validação cruzada, sem queda relevante, o que afasta a hipótese de sobreajuste. A Random Forest alcança precisão perfeita, sem nenhum falso positivo, mas acumula quatro falsos negativos. Trocar um falso positivo por um falso negativo é desvantajoso neste contexto, pois o primeiro custa um exame adicional e o segundo custa um diagnóstico perdido.

Figura 2 - Matriz de confusão do modelo escolhido



Fonte: elaborado pelo autor.

O modelo acerta 110 dos 114 casos, com 71 verdadeiros negativos, 39 verdadeiros positivos, 1 falso positivo e 3 falsos negativos. Com recall de 0,929, escapam aproximadamente 1 em cada 14 tumores malignos, resultado adequado a um sistema de apoio e inaceitável para decisão autônoma.

5.2 Ajuste do limiar de decisão

Tabela 8 - Efeito do limiar sobre as métricas e sobre os erros

Limiar	Recall	Precisão	F1	Falsos negativos	Falsos positivos
0,50 (padrão)	0,929	0,975	0,951	3	1
0,30	0,976	0,976	0,976	1	1

Fonte: elaborado pelo autor.

O limiar de 0,50 é apenas a convenção do método `predict()`, e não uma escolha clínica. Sua redução para 0,30 melhora todas as métricas simultaneamente, e duas pacientes a

mais com tumor maligno seriam corretamente sinalizadas sem aumento de exames desnecessários.

Cabem duas ressalvas. Com 114 casos de teste, uma diferença de dois falsos negativos é estatisticamente frágil e pode não se repetir em outra amostra, e o limiar ideal deveria ser calibrado por validação cruzada no treino, e não pela observação do conjunto de teste. A direção do ajuste, contudo, é defensável independentemente do valor exato, pois o custo assimétrico dos erros torna racional um limiar inferior a 0,50 para triagem.

6 EXPLICABILIDADE

Um sistema de apoio ao diagnóstico que não explica sua previsão não é utilizável na prática, pois o médico precisa poder concordar ou discordar com base no raciocínio, e não apenas no número. Foram aplicadas três técnicas independentes.

Quadro 9 - Cinco maiores coeficientes da Regressão Logística

Feature	Coeficiente	Razão de chances
texture_worst	+1,434	4,20
radius_se	+1,233	3,43
symmetry_worst	+1,061	2,89
concave points_mean	+0,953	2,59
concavity_worst	+0,911	2,49

Fonte: elaborado pelo autor.

Com as features padronizadas, os coeficientes são comparáveis entre si e a razão de chances tem leitura direta. Um resultado aparentemente contraditório merece explicação: o maior coeficiente é `texture_worst`, e não `concave points_worst`, que liderava o *d* de Cohen. A causa é a multicolinearidade descrita na seção 3.3, pois `concave points_worst` é altamente correlacionada com outras medidas e a regularização L2 distribui o peso entre todas elas. Por ser relativamente independente, `texture_worst` carrega informação que nenhuma outra feature fornece. Coeficiente elevado significa informação única e útil ao modelo, e não medida clinicamente mais importante.

Tabela 10 - Importância por permutação, medida sobre o recall

Feature	Queda média em recall	Desvio
texture_worst	0,0540	0,0212
concavity_worst	0,0421	0,0243
symmetry_worst	0,0278	0,0185
concave points_worst	0,0262	0,0188

radius_worst


0,0040

0,0205

Fonte: elaborado pelo autor.

A permutação foi medida sobre o recall, e não sobre a acurácia, porque uma feature pode ser importante para o acerto geral e irrelevante para a detecção de casos malignos. Embaralhar `texture_worst` reduz o recall em 5,4 pontos percentuais, e a partir da quinta feature a queda é praticamente nula, o que mostra que o modelo se apoia em poucas medidas.


Figura 3 - Valores SHAP para o conjunto de teste



Fonte: elaborado pelo autor.

Na visão global do SHAP, cada ponto representa uma paciente. A posição horizontal indica o quanto a medida empurrou a previsão para maligno, à direita, ou para benigno, à esquerda, e a cor indica se o valor era alto ou baixo. Para quase todas as features do topo, valores altos empurram a previsão para maligno, exatamente como descreve a literatura médica.

Figura 4 - Decomposição SHAP de um tumor maligno não detectado



Fonte: elaborado pelo autor.

A decomposição de um dos três falsos negativos é o resultado mais informativo do trabalho. Praticamente todas as medidas dessa paciente estão abaixo da média da base, com `texture_worst` a $-0,83$ desvios padrão, `texture_mean` a $-0,85$ e `symmetry_worst` a $-0,52$, e cada uma delas empurrou a previsão para benigno.

Em linguagem clínica, trata-se de um tumor maligno cujos núcleos apresentam morfologia pouco característica. O modelo não errou por acaso: observou um caso que genuinamente se assemelha aos benignos nas 30 medidas disponíveis. Nenhum ajuste de hiperparâmetro resolve essa situação, porque a informação necessária não está nos dados. A explicação, por outro lado, é acionável, pois o médico que examina a decomposição percebe que a previsão se apoia em medidas fracas, sem sinal forte em sentido contrário, o que justifica exames complementares.

As features `texture_worst`, `concavity_worst`, `symmetry_worst` e `concave points` aparecem no topo das três análises, obtidas por caminhos matematicamente independentes. A concordância aumenta a confiança de que o modelo aprendeu sinal real, e não artefato da partição dos dados.

7 DISCUSSÃO CRÍTICA

7.1 O modelo pode ser usado na prática?

O modelo é utilizável como ferramenta de apoio, jamais como decisor. O desempenho sustenta essa posição, com recall de 0,929 e AUC de 0,996 no teste, sem queda em relação à validação cruzada e com explicações coerentes com a morfologia celular descrita na literatura. Três limitações, contudo, delimitam onde o uso autônomo seria irresponsável.

A base tem origem única e volume reduzido. São 569 casos de uma única instituição, coletados sob um único protocolo, e nada garante que o desempenho se mantenha em outra população ou com outro profissional extraíndo as medidas. O conjunto de teste tem 114 casos, e a diferença entre três e um falso negativo equivale a duas pacientes.

O sistema também não parte de dados brutos. As 30 features já resultam da análise prévia de um especialista que examinou a imagem e mediu os núcleos celulares. O modelo automatiza o julgamento a partir das medidas, e não a extração delas, de modo que não reduz a carga de trabalho especializada. A entrega complementar descrita na seção 8 ataca precisamente essa limitação.

Por fim, existem tumores malignos morfologicamente discretos, como o caso analisado na seção 6.

7.2 Cenários de uso e riscos de implantação

Quadro 11 - Cenários de uso do modelo no fluxo clínico

Cenário	Como funcionaria	Por que agrega valor
Priorização de fila	ordenar os casos pendentes pela probabilidade prevista	casos de alto risco chegam antes ao especialista, sem excluir ninguém
Segunda opinião	exibir previsão, probabilidade e explicação junto ao laudo em elaboração	oferece contraponto estruturado antes da assinatura
Sinalização de discordância	alertar quando o modelo e o laudo preliminar divergem	funciona como rede de segurança contra desatenção

Fonte: elaborado pelo autor.

Em todos os cenários o laudo é assinado por um médico. O sistema nunca emite diagnóstico, nunca dispensa uma paciente e nunca constitui a última etapa do fluxo. O limiar de decisão, por sinal, é uma escolha clínica e não técnica: quem deve defini-lo é a instituição de saúde, pois ele traduz quantos exames adicionais se aceita realizar para não deixar um

tumor maligno passar. O que a análise entrega é a curva de compromisso que torna essa decisão informada.

Quanto aos riscos, um sistema que acerta 96,5% das vezes pode induzir excesso de confiança e levar o profissional a aceitar previsões sem revisão, efeito que a explicabilidade busca combater. Há também o risco de degradação silenciosa, pois mudanças de equipamento, protocolo ou população deslocam a distribuição dos dados sem gerar erro visível, o que exigiria monitoramento contínuo em produção. Comunicar `texture_worst` como a medida que mais importa no diagnóstico seria erro grave de tradução entre estatística e medicina. Além disso, o sistema opera sobre dados sensíveis de saúde, o que exige conformidade com a Lei Geral de Proteção de Dados e definição explícita de responsabilidade sobre o desfecho.

Os próximos passos técnicos são a validação externa em base de outra instituição, a calibração do limiar por validação cruzada no treino, a calibração de probabilidade para que o valor previsto possa ser lido como risco real, e o diagnóstico a partir de imagem.

8 ENTREGA COMPLEMENTAR: DIAGNÓSTICO POR IMAGEM

O pipeline tabular não parte de dados brutos, pois recebe medidas que um especialista já extraiu. Esta entrega ataca essa limitação classificando diretamente a partir do pixel, com a base BUSI (AL-DHABYANI et al., 2020), composta por 780 imagens de ultrassom mamário em três classes: 437 benignas, 210 malignas e 133 normais.

Antes de qualquer métrica foi preciso corrigir um defeito da base. Uma auditoria por hash perceptual identificou 668 grupos de imagens distintas entre as 780, ou seja, 112 imagens são quadros repetidos de exames já presentes. Alocadas ao acaso, 62 pares caíam em partições diferentes, e a rede acabava avaliada em imagens já vistas no treino. A correção foi tratar cada grupo como unidade indivisível por meio do `StratifiedGroupKFold`, que preserva a proporção das classes e nunca separa um grupo, resultando em 556 imagens de treino, 112 de validação e 112 de teste.

Tabela 12 - Desempenho das três arquiteturas nas 112 imagens de teste

Modelo	Acurácia	F1 macro	Recall maligno	Precisão maligno	Não detectados
MobileNetV2 (ajuste fino)	0,839	0,821	0,900	0,771	3 de 30
MobileNetV2 (transferência)	0,759	0,751	0,767	0,622	7 de 30

CNN do zero	treinada	0,563	0,240	0,000	0,000	30 de 30
----------------	----------	-------	-------	-------	-------	----------

Fonte: elaborado pelo autor.

A rede treinada do zero não aprendeu a tarefa: com 56,3% de acurácia, não detectou nenhum dos 30 casos malignos, pois aprendeu a responder benigno, a resposta mais frequente. É a demonstração prática do argumento da seção 4.2, já que o modelo exibe mais da metade de acerto e possui valor clínico nulo. A transferência de aprendizado torna a tarefa viável, e o ajuste fino a torna razoável: a liberação das 60 camadas finais elevou o recall da classe maligna de 0,767 para 0,900 e ainda melhorou a precisão.

A explicabilidade usa Grad-CAM, equivalente visual do SHAP para imagens, que responde onde a rede olhou. Nos casos detectados corretamente o calor se concentra sobre a lesão; nos casos que escaparam, a lesão permanece fria e o calor migra para uma região de sombra acústica sem relevância diagnóstica, ou seja, o modelo sequer considerou a lesão. Com recall de 0,900, aproximadamente 1 em cada 10 tumores malignos ainda escaparia, resultado adequado a uma demonstração de viabilidade acadêmica e insuficiente para uso clínico.

9 REPRODUTIBILIDADE E EXECUÇÃO

O projeto está organizado em `src/`, dividido em 11 módulos que cobrem configuração, dados, pré-processamento, análise exploratória, modelos, avaliação, explicabilidade, gráficos, geração de relatório e o pacote de visão computacional. Dois scripts executam cada pipeline de ponta a ponta, e 86 testes automatizados cobrem desde o carregamento dos dados até a geração do relatório.

A semente aleatória é fixa em todas as etapas e as versões das dependências estão travadas. Executar o pipeline duas vezes produz o mesmo arquivo de métricas, e a execução em container Linux produz o mesmo arquivo que a execução local em Windows, verificado campo a campo. Nenhum número deste relatório foi escrito manualmente: todos provêm de `results/metrics.json` e `results/metrics_vision.json`.

A execução com Docker dispensa qualquer instalação prévia de Python:

```
git clone https://github.com/gustavofks/ML-breast-cancer.git
cd ML-breast-cancer
docker build -t ml-breast-cancer .
docker run --rm -v "$(pwd)/results:/app/results" ml-breast-cancer
```

A execução local requer Python 3.11:

```
py -3.11 -m venv .venv
.venv\Scripts\activate
pip install -r requirements.txt
python scripts/run_wisconsin.py
```

O clone já traz o dataset tabular, as 21 figuras, as métricas e o relatório visual gerados, de modo que o resultado pode ser conferido sem executar nada, bastando abrir `results/reports/index.html` no navegador. A entrega complementar possui dependências próprias e requer a base BUSI, que não é versionada em razão do tamanho; com Docker, ela corresponde a um estágio separado do mesmo `Dockerfile`.

10 CONSIDERAÇÕES FINAIS

O trabalho entrega um classificador com desempenho alto, estável e explicável, construído sobre um protocolo metodológico defensável: sem vazamento de dados, com separação clara entre treino e teste, métrica escolhida pelo custo clínico do erro e três técnicas independentes de explicabilidade convergindo nos mesmos achados.

Seu valor prático não está em substituir o julgamento médico, e sim em torná-lo mais rápido e mais informado, por meio da priorização de filas, da segunda opinião estruturada e da sinalização de divergências. O caso do tumor maligno não detectado, analisado pela decomposição SHAP, é o argumento mais concreto em favor dessa posição: existem limites que o dado disponível não permite ultrapassar, e reconhecê-los faz parte de entregar o sistema de forma responsável.

REFERÊNCIAS

AL-DHABYANI, W.; GOMAA, M.; KHALED, H.; FAHMY, A. Dataset of breast ultrasound images. **Data in Brief**, 2020.

LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. In: **Advances in Neural Information Processing Systems (NIPS)**, 2017.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, 2011.

SANDLER, M.; HOWARD, A.; ZHU, M.; ZHMOGINOV, A.; CHEN, L.-C. MobileNetV2: inverted residuals and linear bottlenecks. In: **IEEE Conference on Computer Vision and Pattern Recognition (CVPR)**, 2018.

SELVARAJU, R. R. et al. Grad-CAM: visual explanations from deep networks via gradient-based localization. In: **IEEE International Conference on Computer Vision (ICCV)**, 2017.

UCI MACHINE LEARNING REPOSITORY. **Breast Cancer Wisconsin (Diagnostic) Data Set**. Disponível em: <https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data>. Acesso em: 2026.

APÊNDICE A – RASTREABILIDADE DAS EXIGÊNCIAS DO DESAFIO

Quadro 13 - Correspondência entre as exigências do enunciado e as seções deste relatório

Exigência do enunciado	Onde está	Evidência
Dataset público de saúde da mulher, com o problema discutido	Seção 1	Breast Cancer Wisconsin, 569 amostras
Carregar a base e explorar suas características	Seção 2	<code>src/data.py</code> , <code>src/eda.py</code> , notebook 01
Estatísticas descritivas e distribuições relevantes	Seção 2.1	distribuição das classes e tabela do d de Cohen
Padrões relacionados à saúde feminina	Seção 2.2	ranking de separação por feature
Limpeza de valores ausentes e inconsistentes	Seção 3.1	coluna fantasma e id removidos
Pipeline de pré-processamento em Python	Seção 3.2	<code>src/preprocessing.py</code>
Conversão de variáveis categóricas e numéricas	Seções 3.1 e 3.2	alvo M/B para 1/0, features padronizadas
Análise de correlação	Seção 3.3	21 pares acima de 0,9
Duas ou mais técnicas de classificação	Seção 4.1	Regressão Logística, KNN e Random Forest
Separação clara entre treino e teste	Seção 3.4	80/20 estratificado, teste intocado
Treino no conjunto de treinamento	Seção 4.3	validação cruzada de cinco partições
Avaliação no teste com accuracy, recall e F1	Seção 5.1	tabela de desempenho no teste
Discussão da escolha da métrica	Seção 4.2	recall maligno como prioridade, F1 para selecionar
Interpretação com feature importance e SHAP	Seção 6	coeficientes, permutação e SHAP
Discussão crítica sobre uso na prática	Seção 7	cenários de uso e limitações
Projeto Python estruturado e documentado	Seção 9	11 módulos, 86 testes automatizados
Notebook ou scripts para demonstração	Seção 9	3 notebooks com saídas, 2 scripts
README com instruções de execução	Repositório	README.md
Dockerfile	Seção 9	Dockerfile, com estágio para a entrega de imagem
Dataset ou link para download	Seção 1	<code>data/raw/data.csv</code> versionado
Resultados obtidos, com gráficos e análises	Seções 5 e 6	21 figuras, relatório visual em HTML
Entrega extra com visão computacional	Seção 8	<code>src/vision/</code> , notebook 03

Fonte: elaborado pelo autor.