FIAP - Faculdade de Informática e Administração Paulista
Pós-graduação em Inteligência Artificial para Desenvolvedores

Gustavo Feikes Marino de Siqueira

OTIMIZAÇÃO GENÉTICA E EXPLICAÇÕES EM LINGUAGEM NATURAL PARA APOIO AO DIAGNÓSTICO DE CÂNCER DE MAMA

Síntese do Tech Challenge da Fase 2

Relatório técnico apresentado como requisito de avaliação do Tech Challenge da Fase 2 do curso de Pós-graduação em Inteligência Artificial para Desenvolvedores da FIAP.

São Paulo
2026

Link do repositório: https://github.com/gustavofks/ML-breast-cancer

Link do vídeo: https://www.youtube.com/watch?v=-YmjWl66jtU

Link da vitrine no Hugging Face: https://huggingface.co/spaces/gustavofks/apoio-diagnostico-cancer-mama

Relatório técnico completo: https://github.com/gustavofks/ML-breast-cancer/blob/main/docs/relatorio_tecnico_fase2.pdf

RESUMO

Este relatório sintetiza a Fase 2 do sistema de apoio ao diagnóstico de câncer de mama construído na Fase 1 sobre a base Breast Cancer Wisconsin. Um algoritmo genético otimiza conjuntamente as medidas, os hiperparâmetros e o limiar de decisão contra um custo clínico em que o falso negativo pesa 10 vezes o falso positivo, avaliado por validação cruzada dentro do treino. Foram 45 buscas, em 4 configurações do algoritmo, 3 famílias de modelo e 3 sementes, mais braços de ablação que isolam de onde vem o ganho. O ganho em segurança vem de mover o ponto de operação, e não da seleção de medidas: no teste, os braços que só ajustam o limiar ou o peso das classes chegam a 1 falso negativo, contra 3 da referência da Fase 1, e a seleção de medidas mantém a segurança da referência com 5 das 30 medidas. O Claude Haiku 5.5 gera, em lote, a explicação de cada previsão e dois textos de gestão; 116 de 116 passaram nas quatro verificações automáticas, a um custo de US$ 0,046, e uma rubrica humana mediu a utilidade. O sistema é servido como API monitorada, com uma vitrine interativa publicada gratuitamente em nuvem.

Palavras-chave: algoritmos genéticos; modelos de linguagem; apoio ao diagnóstico; custo clínico.

SUMÁRIO

RESUMO 2

1 INTRODUÇÃO 4

2 ARQUITETURA 4

3 ALGORITMO GENÉTICO 5

3.1 Codificação e função fitness 5

3.2 Operadores e experimentos 5

4 RESULTADOS DA OTIMIZAÇÃO 6
4.1 Convergência 6
4.2 De onde vem o ganho 6
4.3 Comparação com os modelos originais 7
5 INTEGRAÇÃO COM MODELO DE LINGUAGEM 7
5.1 Abordagem 7
5.2 Prompt engineering 8
5.3 Avaliação da qualidade 8
6 SERVIÇO, MONITORAMENTO E NUVEM 8
7 DESAFIOS E SOLUÇÕES 10
8 REPRODUTIBILIDADE 10
9 CONSIDERAÇÕES FINAIS 10
REFERÊNCIAS 10
APÊNDICE A – RASTREABILIDADE DAS EXIGÊNCIAS DO DESAFIO 11

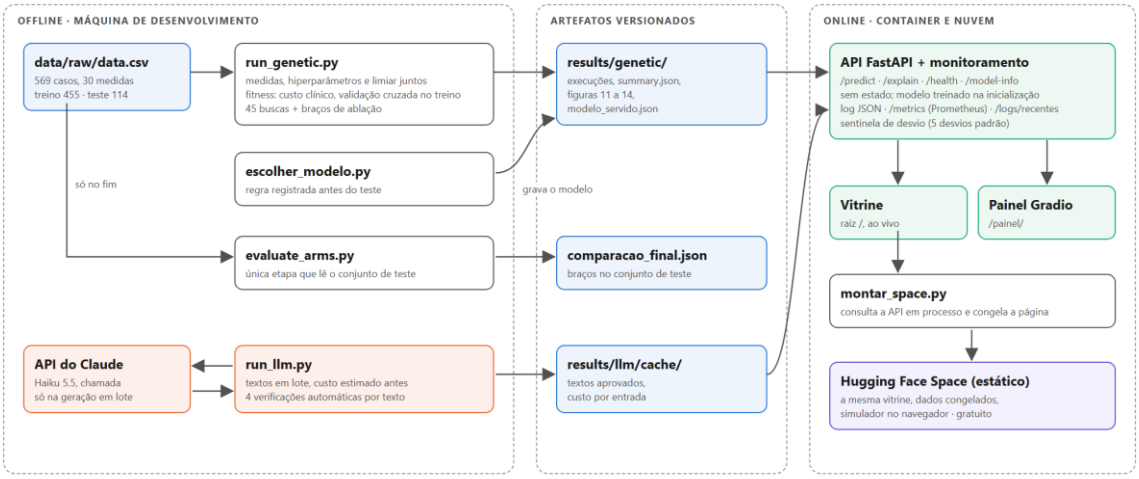
1 INTRODUÇÃO

Este trabalho segue o Projeto 1 do enunciado, otimização de modelos de diagnóstico, e dá continuidade direta à Fase 1, que entregou uma regressão logística com recall de 0,929 na classe maligna e 3 falsos negativos nos 114 casos de teste.

A busca em grade da Fase 1 já tinha saturado os hiperparâmetros: a regressão logística ficou no valor padrão. Um algoritmo genético no mesmo espaço produziria empate técnico. O terreno em que ele é insubstituível é o combinatório, e a Fase 1 deixou dois espaços assim abertos: a seleção entre 30 medidas, mais de um bilhão de subconjuntos, e o limiar de decisão, que a Fase 1 escolheu olhando o teste e registrou como fragilidade. Por isso a Fase 2 otimiza medidas, hiperparâmetros e limiar juntos, por validação cruzada dentro do treino.

2 ARQUITETURA

Figura 1 - Arquitetura da solução: etapas offline, artefatos versionados e serviço online



Fonte: elaborado pelo autor.

As etapas pesadas, as buscas genéticas, e a única que custa dinheiro, a geração de textos, rodam uma vez e gravam arquivos versionados. O serviço só lê esses arquivos: não precisa de modelo de linguagem, chave de API nem internet. Os módulos da Fase 1 foram reaproveitados sem alteração; o algoritmo genético importa o mesmo `build_pipeline` e a mesma validação cruzada, o que torna legítima a comparação entre modelos originais e otimizados.

3 ALGORITMO GENÉTICO

3.1 Codificação e função fitness

O cromossomo tem três segmentos tipados, cada um com operador próprio: a máscara binária das 30 medidas, os hiperparâmetros da família de modelo e o limiar de decisão, real entre 0,05 e 0,95. Um reparo após cada operador garante que nenhum indivíduo inválido chegue ao fitness.

```
custo   = (C_FN × falsos negativos + C_FP × falsos positivos) / n
fitness = 1 − custo / C_FN − α × (medidas ativas / 30)
```

Com `C_FN = 10`, `C_FP = 1` e $\alpha = 0{,}05$, um desempate em favor de modelos com menos medidas. O fitness é avaliado por validação cruzada de 5 partições dentro do treino, com o limiar do próprio indivíduo; o conjunto de teste só é lido na comparação final, e há teste automatizado que falha se o fitness o tocar.

3.2 Operadores e experimentos

A seleção é por torneio com elitismo de dois indivíduos; o cruzamento é uniforme na máscara, aritmético nos genes reais e por troca nos categóricos; a mutação troca bits, perturba os reais em escala logarítmica e sorteia os categóricos.

Tabela 1 - Configurações do algoritmo genético

Experimento	População	Gerações	Mutação	Cruzamento	Torneio	Elitismo
E1 base	40	30	0,10	0,80	3	2
E2 exploração	80	30	0,25	0,60	2	2
E3 explotação	20	60	0,05	0,90	5	2
E4 sem elitismo	40	30	0,10	0,80	3	0

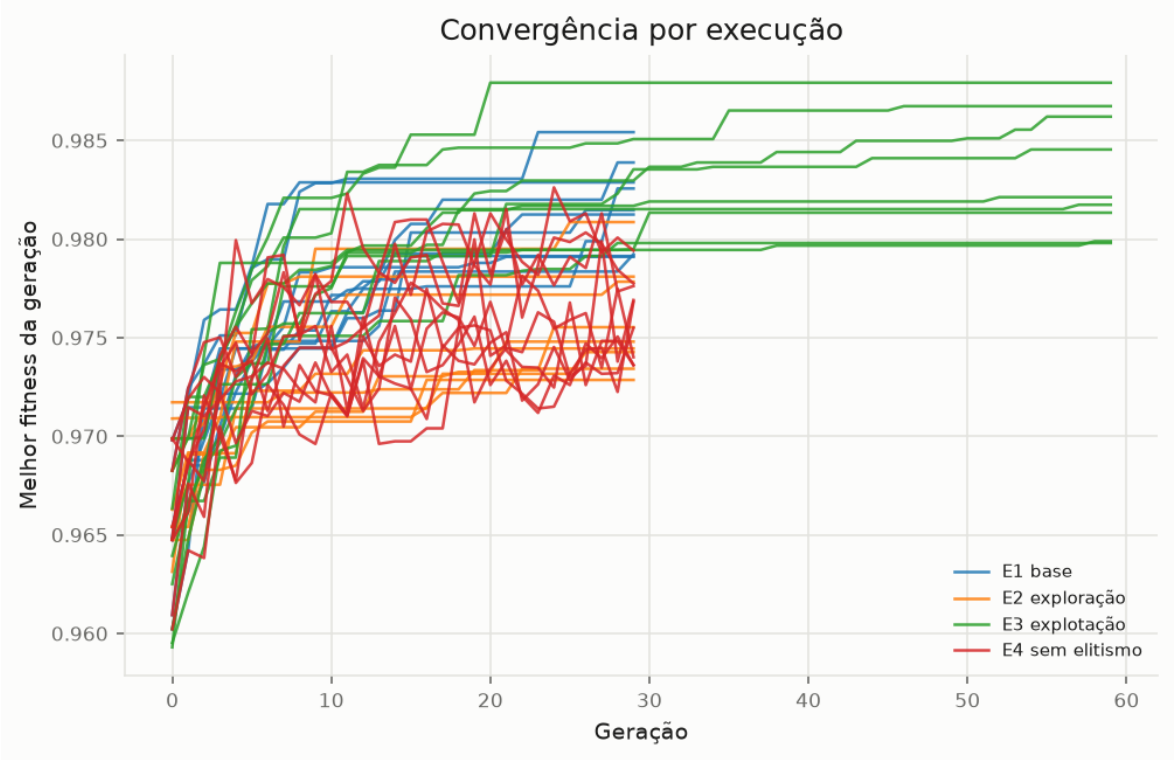
Fonte: elaborado pelo autor.

Cada configuração rodou sobre as três famílias com três sementes, num total de 45 buscas e 59.069 avaliações. Braços de ablação otimizam só o limiar, só as medidas ou só os hiperparâmetros da regressão logística, para isolar de onde vem o ganho.

4 RESULTADOS DA OTIMIZAÇÃO

4.1 Convergência

Figura 2 - Melhor fitness por geração em cada execução, colorido por configuração



Fonte: elaborado pelo autor.

Com elitismo (E1 a E3), o melhor fitness nunca cai; sem ele (E4), as curvas oscilam e o melhor indivíduo se perde. A regressão logística teve o menor custo em todas as configurações, confirmando a escolha da Fase 1 por um caminho independente. Nas 225 reavaliações com outra semente de partição, a queda média de fitness foi de 0,0020: sem sinal de sobreajuste.

4.2 De onde vem o ganho

Tabela 2 - Braços de ablação na validação cruzada, média de três sementes

Braço	Custo clínico médio	Desvio	FN médio	FP médio	Medidas
só limiar	0,0791	0,0000	2,00	16,00	30,00
completo	0,0872	0,0063	2,00	19,67	4,33
só hiperparâmetros	0,1385	0,0000	6,00	3,00	30,00
só features	0,1626	0,0171	7,00	4,00	6,67

Fonte: elaborado pelo autor.

Otimizar só o limiar produz o menor custo clínico; otimizar só as medidas, o maior. O braço completo fica próximo do limiar com uma fração das medidas. O ganho em segurança

vem de mover o ponto de operação; a seleção de medidas entrega economia de medidas sem perder segurança.

4.3 Comparação com os modelos originais

O modelo servido foi escolhido por uma regra gravada em 11/10/2026, antes da comparação final: o indivíduo de maior fitness em validação cruzada, com trava que devolve a referência se ele tiver mais falsos negativos que ela no teste. O escolhido é uma regressão logística com 5 medidas e limiar 0,2274.

Tabela 3 - Todos os braços nos casos de teste, ordenados por falsos negativos

Abordagem	**Medidas**	**Limiar**	**FN**	**FP**	**Recall**	**AUC**	**Custo clínico**
só hiperparâmetros	30	0,5000	1	1	0,9762	0,9977	0,0965
só limiar	30	0,1833	1	4	0,9762	0,9960	0,1228
Original	30	0,5000	3	1	0,9286	0,9960	0,2719
Busca em grade	30	0,5000	3	1	0,9286	0,9960	0,2719
completo (servido)	5	0,2274	3	4	0,9286	0,9901	0,2982
só features	6	0,5000	4	1	0,9048	0,9947	0,3596

Fonte: elaborado pelo autor.

A trava não disparou. Os braços que só movem o ponto de operação chegam a 1 falso negativo; o modelo servido empata com a referência, com 5 medidas em vez de 30. Com 42 casos malignos no teste, cada falso negativo vale 0,088 de custo clínico, e diferenças de um ou dois casos estão dentro do ruído. O modelo servido não é o melhor do teste, e mantê-lo é deliberado: trocá-lo pelo melhor do teste seria escolher pelo teste.

5 INTEGRAÇÃO COM MODELO DE LINGUAGEM

5.1 Abordagem

Os textos são gerados uma vez, em lote, pelo Claude Haiku 5.5 via API, e gravados num cache versionado que a API serve. Toda a camada fala com uma interface de provedor; trocar o modelo é uma linha de configuração, e é essa interface que prepara a integração com dados textuais no Módulo 3. O custo é travado no código, com estimativa de pior caso antes da primeira chamada. O lote de 118 textos custou US$ 0,046.

Três produtos de texto: a explicação de cada previsão para o médico, um resumo de métricas para a gestão clínica e uma nota sobre o que o algoritmo genético mudou.

5.2 Prompt engineering

Os prompts são versionados e aplicam papel e fronteira no prompt de sistema (apoio à decisão, nunca diagnóstico), evidência em JSON em vez de prosa, um exemplo resolvido, contrato de saída com seções e limite de palavras, e a proibição de números que não estejam na evidência. A comparação entre versões mostrou que o modelo trata o limite pedido como alvo aproximado: a primeira versão da nota de mudança pedia o limite exato do verificador e passou dele, com 229 palavras; a segunda pede 180 e ficou dentro.

5.3 Avaliação da qualidade

Tabela 4 - Verificações automáticas e resultado do lote

Verificação	Mecanismo	O que detecta	Aprovados
fidelidade	todo número do texto existe na evidência, com sinal	alucinação de estatística	116 de 116
seguranca	padrões de afirmação diagnóstica, com negação; ressalva obrigatória	texto que se passaria por laudo	116 de 116
cobertura	as três medidas de maior contribuição são citadas	explicação genérica	116 de 116
formato	seções do contrato presentes e limite de palavras	saída fora do contrato	116 de 116

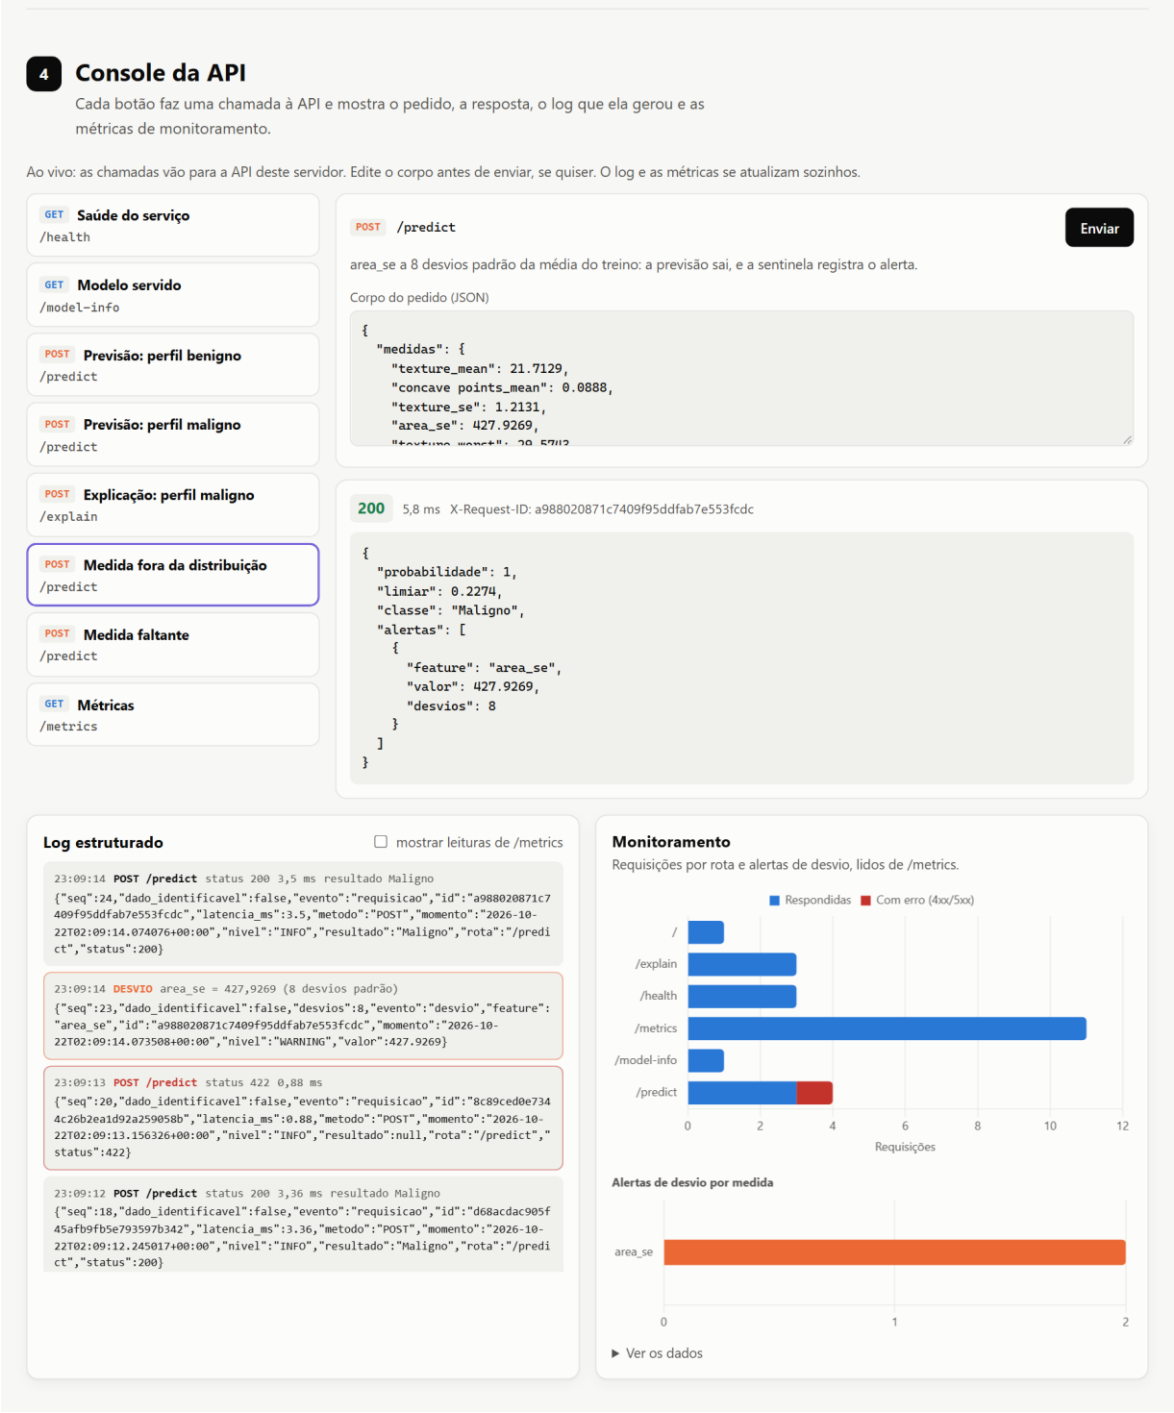
Fonte: elaborado pelo autor.

Texto reprovado nunca chega à tela. As verificações conferem fatos, não utilidade, então uma rubrica humana pontuou 7 textos, escolhidos entre erros do modelo, casos perto do limiar e os textos de gestão. A média foi 4,0; a clareza teve 4,9 e a utilidade, 3,0, caindo para 2,0 nos casos de erro. O texto descreve a previsão com correção, mas não sinaliza quando ela pode estar errada. Parte disso é estrutural, porque o diagnóstico real não existe no momento da previsão; a parte corrigível é tratar a proximidade do limiar como motivo de cautela, o próximo passo da camada de linguagem.

6 SERVIÇO, MONITORAMENTO E NUVEM

A API FastAPI expõe `/predict`, `/explain`, `/health`, `/model-info`, `/metrics` e `/logs/recentes`, com documentação interativa em `/docs`. Cada requisição gera uma linha de log em JSON; `/metrics` expõe contadores, latências e alertas no formato do Prometheus; e uma sentinela de desvio alerta quando uma medida recebida foge por mais de 5 desvios padrão da distribuição do treino.

Figura 3 - Console da vitrine ao vivo: medida fora da distribuição, alerta no log e métricas atualizadas



Fonte: elaborado pelo autor.

O serviço está preparado para escalar horizontalmente: não guarda estado, carrega o modelo uma vez e expõe saúde e métricas. A escala automática em si exige um orquestrador, que a camada gratuita não oferece; a arquitetura que escalaria é o mesmo container em réplicas atrás de um balanceador, com regra de escala pelas métricas já expostas.

A vitrine interativa está publicada num Space estático do Hugging Face, gratuito. Lá ela usa as respostas da API congeladas na montagem, uma sessão gravada do console e um

simulador que refaz no navegador a conta do modelo servido, verificada contra a API nos 114 casos de teste. No container, a mesma página chama as rotas de verdade.

7 DESAFIOS E SOLUÇÕES

- **Random Forest 45 vezes mais lenta:** teto de 300 árvores e população avaliada em paralelo, com resultado idêntico ao sequencial.
- **Execução interrompida:** opção de retomada, com arquivo final idêntico byte a byte.
- **Verificadores com defeitos encontrados nos textos reais:** sinal dos números e nove falsos positivos de segurança, corrigidos com as frases reais virando testes.
- **Hugging Face passou a cobrar por Spaces que executam código:** vitrine em modo estático, com o simulador verificado contra a API.

8 REPRODUTIBILIDADE

Semente fixa, dependências travadas e resultados versionados: o clone permite conferir tudo sem executar nada. Para subir o serviço e a vitrine:

```
docker build --target api -t ml-breast-cancer:api .
docker run --rm -p 8000:8000 -v "$(pwd)/results:/app/results" ml-breast-
cancer:api
```

A suíte tem mais de 400 testes automatizados em Python e os testes da vitrine em JavaScript; os testes da Fase 1 continuam passando sem alteração.

9 CONSIDERAÇÕES FINAIS

O algoritmo genético foi aplicado onde é insubstituível, e os experimentos foram desenhados para que o resultado pudesse contrariar a expectativa. Contrariou: a segurança vem do ponto de operação, e a seleção de medidas entrega o mesmo nível de segurança com uma fração do trabalho do patologista. O modelo de linguagem transforma cada previsão num texto verificado, e a avaliação humana mostrou o seu limite: ele descreve com precisão o que o modelo viu, e não tem como saber o que deixou de ver. O diagnóstico continua sendo do médico.

REFERÊNCIAS

GOLDBERG, D. E. **Genetic algorithms in search, optimization, and machine learning**. Reading: Addison-Wesley, 1989.

HOLLAND, J. H. **Adaptation in natural and artificial systems**. Ann Arbor: University of Michigan Press, 1975.

LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. In: **Advances in Neural Information Processing Systems (NIPS)**, 2017.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, 2011.

UCI MACHINE LEARNING REPOSITORY. **Breast Cancer Wisconsin (Diagnostic) Data Set**. Disponível em: https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data. Acesso em: 2026.

APÊNDICE A – RASTREABILIDADE DAS EXIGÊNCIAS DO DESAFIO

Tabela 5 - Correspondência entre as exigências do enunciado e as seções deste relatório

Exigência do enunciado	Onde está	Evidência
Algoritmo genético para otimizar os modelos do Módulo 1	Seção 3	`src/genetic/`
Codificação adequada dos genes	Seção 3.1	cromossomo de três segmentos tipados
Operadores de seleção, cruzamento e mutação	Seção 3.2	`src/genetic/operators.py`
Fitness baseada em métricas de desempenho	Seção 3.1	custo clínico por validação cruzada
Comparar modelos otimizados com os originais	Seção 4.3	braços Original e Busca em grade no teste
Ao menos 3 experimentos com configurações diferentes	Seção 3.2	quatro configurações, três sementes cada
Escalabilidade automática	Seção 6	serviço sem estado, com limitação declarada
Monitoramento e logging	Seção 6	log JSON, `/metrics`, sentinela de desvio
Documentar arquitetura e decisões	Seção 2	diagrama e relatório técnico completo
LLM explicando os diagnósticos	Seção 5	explicação por paciente, servida em `/explain`
Números convertidos em insights acionáveis	Seção 5.1	resumo para a gestão clínica
Base para dados textuais do Módulo 3	Seção 5.1	interface de provedor e prompts versionados
Prompt engineering para o contexto médico	Seção 5.2	`src/llm/prompts.py`, duas versões medidas
Avaliar a qualidade das interpretações	Seção 5.3	quatro verificações automáticas e rubrica humana
Projeto Python estruturado com ambiente virtual	Seção 8	`.venv`, `requirements*.txt`, `Dockerfile`
Documentação com diagramas de arquitetura	Seção 2	figura 1 e README
Testes automatizados	Seção 8	mais de 400 testes em Python, testes em JavaScript
Implantação em nuvem, opcional	Seção 6	Space estático no Hugging Face
Documentação da API	Seção 6	`/docs`, gerada pela FastAPI

Exigência do enunciado	Onde está	Evidência
Scripts de demonstração	Seção 8	`scripts/` e a vitrine interativa
Vídeo de demonstração de até 15 minutos	Início do relatório	link no início deste relatório

Fonte: elaborado pelo autor.