

FIAP - Faculdade de Informática e Administração Paulista
Pós-graduação em Inteligência Artificial para Desenvolvedores

Gustavo Feikes Marino de Siqueira

CLASSIFICAÇÃO DE TUMORES DE MAMA COM MACHINE LEARNING

Relatório técnico completo do Tech Challenge da Fase 1

Relatório técnico apresentado como requisito de avaliação do Tech Challenge da Fase 1 do curso de Pós-graduação em Inteligência Artificial para Desenvolvedores da FIAP.

RESUMO

Este relatório documenta, em detalhe, a construção de um sistema de apoio ao diagnóstico de câncer de mama sobre a base Breast Cancer Wisconsin (Diagnostic), com 569 amostras e 30 medidas morfológicas de núcleos celulares. A análise exploratória caracteriza a qualidade da base, o desbalanceamento leve entre as classes, a diferença de até cinco ordens de grandeza entre as escalas das variáveis e os 21 pares de features com correlação acima de 0,9. O pré-processamento é um Pipeline do scikit-learn com imputação por mediana e padronização, mantido dentro da validação cruzada para evitar vazamento de dados. Três técnicas de classificação são comparadas, Regressão Logística, KNN e Random Forest, por validação cruzada estratificada de cinco partições no conjunto de treino. A Regressão Logística é a escolhida e alcança, nos 114 casos de teste, acurácia de 0,965, recall de 0,929 na classe maligna, F1 de 0,951 e AUC de 0,996, com três falsos negativos. A métrica prioritária é o recall da classe maligna, porque o custo clínico de um falso negativo supera em muito o de um falso positivo; reduzir o limiar de decisão de 0,50 para 0,30 diminui os falsos negativos de três para um sem aumentar os falsos positivos. A explicabilidade combina coeficientes, importância por permutação e valores SHAP, que convergem nas mesmas medidas, e a decomposição de um caso não detectado mostra o limite do que os dados disponíveis permitem. Como entrega complementar, o mesmo problema é tratado a partir de imagens de ultrassom da base BUSI, em que uma MobileNetV2 com ajuste fino alcança recall de 0,900 na classe maligna, com explicabilidade por Grad-CAM. Conclui-se que o sistema é adequado ao uso como ferramenta de triagem e segunda opinião, jamais como decisor autônomo.

Palavras-chave: aprendizado de máquina; câncer de mama; apoio ao diagnóstico; explicabilidade; redes neurais convolucionais.

SUMÁRIO

RESUMO.....	2
1 INTRODUÇÃO E DEFINIÇÃO DO PROBLEMA.....	3
2 ANÁLISE EXPLORATÓRIA DOS DADOS.....	3
2.1 Qualidade e integridade da base.....	3
2.2 Distribuição das classes.....	4
2.3 Escalas e assimetria.....	5
2.4 Distribuições por diagnóstico.....	5
2.5 Padrões relacionados ao diagnóstico.....	6
2.6 Síntese dos achados.....	8
3 PRÉ-PROCESSAMENTO.....	8
3.1 Limpeza aplicada.....	8

3.2 Conversão de variáveis.....	9
3.3 Pipeline de pré-processamento.....	9
3.4 Análise de correlação.....	9
3.5 Separação entre treino e teste.....	12
4 MODELAGEM.....	12
4.1 Modelos selecionados.....	12
4.2 Escolha da métrica.....	13
4.3 Protocolo de validação.....	13
5 RESULTADOS E INTERPRETAÇÃO.....	15
5.1 Desempenho no conjunto de teste.....	15
5.2 Matriz de confusão.....	15
5.3 Curvas ROC.....	16
5.4 Ajuste do limiar de decisão.....	17
6 EXPLICABILIDADE.....	18
6.1 Coeficientes da regressão logística.....	19
6.2 Importância por permutação.....	20
6.3 SHAP, visão global.....	21
6.4 SHAP, um caso individual.....	22
6.5 Convergência das três técnicas.....	24
7 DISCUSSÃO CRÍTICA E USO NA PRÁTICA.....	24
7.1 O modelo pode ser usado na prática?.....	24
7.2 Como o modelo seria usado.....	25
7.3 O limiar de decisão é uma escolha clínica, não técnica.....	25
7.4 Riscos de implantação.....	25
7.5 Próximos passos técnicos.....	26
8 ENTREGA COMPLEMENTAR: DIAGNÓSTICO POR IMAGEM COM CNN.....	26
8.1 A base BUSI.....	26
8.2 Duplicatas, o problema que precedeu qualquer métrica.....	28
8.3 Protocolo.....	29
8.4 Arquiteturas comparadas.....	29
8.5 Resultados.....	30
8.6 Explicabilidade, onde a rede olhou.....	32
8.7 Comparação honesta entre as duas entregas.....	34
9 REPRODUTIBILIDADE E EXECUÇÃO.....	34
10 CONSIDERAÇÕES FINAIS.....	36
REFERÊNCIAS.....	37

1 INTRODUÇÃO E DEFINIÇÃO DO PROBLEMA

Uma rede de hospitais e centros de saúde especializados no atendimento à mulher quer um sistema inteligente de apoio ao diagnóstico, capaz de acelerar a triagem e amparar decisões clínicas diante de um volume crescente de pacientes.

Este projeto entrega a base de Machine Learning dessa solução: classificar automaticamente tumores de mama em malignos ou benignos a partir de características morfológicas de núcleos celulares extraídas de imagens de punção aspirativa por agulha fina (PAAF).

A base escolhida é a Breast Cancer Wisconsin (Diagnostic), disponível em <https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data>. São 569 amostras e 30 características numéricas, com diagnóstico confirmado.

A base descreve 10 medidas do núcleo celular (raio, textura, perímetro, área, suavidade, compacidade, concavidade, pontos côncavos, simetria e dimensão fractal), cada uma em três variantes: média da amostra (`_mean`), erro padrão da medida (`_se`) e média das três piores células observadas (`_worst`).

Uma premissa orienta todo o projeto: o modelo é ferramenta de triagem e de segunda opinião, e o diagnóstico final continua sendo responsabilidade do médico. É dela que saem as duas exigências centrais do trabalho, a escolha do recall da classe maligna como métrica prioritária e a obrigação de explicar cada previsão.

O código-fonte, os notebooks executados e o relatório visual estão no repositório <https://github.com/gustavofks/ML-breast-cancer>. Todos os números deste documento são reproduzíveis com `python scripts/run_wisconsin.py`.

2 ANÁLISE EXPLORATÓRIA DOS DADOS

Notebook correspondente: `notebooks/01_exploratory_analysis.ipynb`.

2.1 Qualidade e integridade da base


A base tem 569 registros e nenhum valor ausente real. A única inconsistência é estrutural: o cabeçalho do CSV termina em vírgula, o que faz o pandas criar uma coluna extra `Unnamed: 32` inteiramente nula. Como isso é artefato do arquivo e não dado faltante, o tratamento correto é descartar a coluna, não imputar valores.

Também removi a coluna `id`. Ela identifica o paciente, não tem relação causal com o diagnóstico e, se ficasse, permitiria ao modelo aprender ruído associado à ordem de coleta.

A variável alvo `diagnosis` é categórica (M/B) e foi codificada como $M = 1$ e $B = 0$. Maligno é a classe positiva porque é o evento que se quer detectar, e porque errar nele custa mais caro.

2.2 Distribuição das classes

Figura 1 - Distribuição dos diagnósticos na base



Fonte: elaborado pelo autor.

Tabela 1 - Distribuição das classes na base completa

Classe	Amostras	Proporção
Benigno	357	62,7%
Maligno	212	37,3%

Fonte: elaborado pelo autor.

O desbalanceamento é leve e não exige reamostragem, mas tem duas consequências diretas.

A primeira é que a acurácia isolada engana. Um classificador que respondesse "benigno" para toda paciente já atingiria 62,7% de acurácia. Esse é o piso contra o qual qualquer resultado precisa ser comparado.

A segunda é que a divisão treino/teste precisa ser estratificada, preservando a proporção das classes nos dois conjuntos para que a avaliação continue representativa.

2.3 Escalas e assimetria


Duas características das features condicionam todo o pré-processamento.

As escalas são radicalmente diferentes. `area_worst` varia por milhares de unidades enquanto `fractal_dimension_se` varia por centésimos, cerca de cinco ordens de grandeza de diferença. Algoritmos baseados em distância (KNN) ou em otimização com regularização (regressão logística) seriam dominados pelas variáveis de maior magnitude.

E há assimetria à direita. Várias features, principalmente as do grupo `_se`, têm cauda longa à direita: a maioria das amostras em valores baixos e poucos casos com valores muito altos. Isso é esperado em medidas biológicas de tamanho e irregularidade.

2.4 Distribuições por diagnóstico

Figura 2 - Distribuição das medidas médias por diagnóstico




Fonte: elaborado pelo autor.

As medidas de tamanho e de irregularidade (`radius_mean`, `perimeter_mean`, `area_mean`, `concavity_mean`, `concave points_mean`) mostram tumores malignos deslocados para valores mais altos, com sobreposição apenas parcial entre as classes.

Já `smoothness_mean`, `symmetry_mean` e `fractal_dimension_mean` têm distribuições quase sobrepostas. Isoladamente, quase não distinguem os grupos.

Figura 3 - Dispersão das medidas do grupo worst




Fonte: elaborado pelo autor.

O grupo `_worst` separa as classes com mais nitidez que o grupo `_mean`. O achado tem sentido clínico: o que caracteriza malignidade não é o comportamento médio do tecido, e sim a existência de células com morfologia mais agressiva. A "pior" célula da amostra é mais informativa que a célula típica.

Os pontos fora dos bigodes são numerosos, mas não são erros de medição. São casos extremos reais, concentrados na classe maligna. Removê-los descartaria justamente os casos mais graves, exatamente os que o modelo precisa acertar. Nenhum outlier foi removido neste projeto.

2.5 Padrões relacionados ao diagnóstico

Figura 4 - Quinze features com maior poder de separação



Fonte: elaborado pelo autor.

O d de Cohen mede a distância entre as médias das duas classes em unidades de desvio padrão. Por ser adimensional, permite comparar features de escalas muito diferentes. Valores acima de 0,8 já indicam efeito grande.

Tabela 2 - Features com maior poder de separação entre as classes

Feature	Média benigno	Média maligno	d de Cohen
concave points_worst	0,0744	0,1822	2,69
perimeter_worst	87,01	141,37	2,60
concave points_mean	0,0257	0,0880	2,54
radius_worst	13,38	21,13	2,54
perimeter_mean	78,08	115,37	2,29

Fonte: elaborado pelo autor.

Concavidade e pontos côncavos lideram o ranking. Eles medem o quanto o contorno do núcleo é irregular e reentrante, uma assinatura morfológica clássica de células malignas. As medidas de tamanho vêm logo em seguida, porque núcleos malignos são maiores.

Todos os valores de d no topo são positivos, ou seja, as medidas são sistematicamente maiores nos tumores malignos, sem inversão de sinal entre as principais features. Textura, simetria e dimensão fractal ficam no fim do ranking, com poder de separação fraco quando olhadas sozinhas, o que não impede que contribuam em combinação com as demais.

Raio, perímetro e área descrevem essencialmente a mesma geometria, o que antecipa forte multicolinearidade. Ela é quantificada na seção 3.4.

2.6 Síntese dos achados

Tabela 3 - Achados da análise exploratória e suas consequências para o projeto

Achado	Consequência
Nenhum valor ausente real, só a coluna fantasma do CSV	Limpeza estrutural, sem imputação
<code>id</code> é identificador sem valor preditivo	Removida
Alvo categórico M/B	Codificado como M = 1 (positivo) e B = 0
62,7% benignos contra 37,3% malignos	Acurácia isolada insuficiente, split estratificado
Escalas com até cinco ordens de grandeza de diferença	<code>StandardScaler</code> dentro do pipeline
Assimetria à direita, muitos outliers legítimos	Outliers preservados
Grupo <code>_worst</code> separa melhor que <code>_mean</code>	Confirmado depois pela importância dos modelos
Concavidade e tamanho lideram a separação	Coerente com a morfologia de células malignas
Raio, perímetro e área medem a mesma geometria	Multicolinearidade analisada na seção 3.4

Fonte: elaborado pelo autor.

3 PRÉ-PROCESSAMENTO

Código correspondente: `src/preprocessing.py`.

3.1 Limpeza aplicada

Tabela 4 - Tratamentos aplicados na etapa de limpeza

Problema	Tratamento	Justificativa
Coluna <code>Unnamed: 32</code> , totalmente nula	Removida	Artefato da vírgula final no cabeçalho do CSV, não é dado faltante
Coluna <code>id</code>	Removida	Identificador do paciente, sem relação causal com o diagnóstico
Alvo <code>diagnosis</code> categórico (M/B)	Codificado como M = 1, B = 0	Maligno é a classe positiva, é o evento a detectar
Outliers nas medidas morfológicas	Preservados	São casos malignos extremos reais, não erros de medição
Valores ausentes	Nenhum na base	Imputador de mediana mantido no pipeline por robustez

Fonte: elaborado pelo autor.

A decisão de preservar outliers merece destaque. Em uma base clínica, os valores extremos costumam ser os casos mais graves. Removê-los melhoraria as métricas de forma enganosa, eliminando justamente as pacientes que o sistema mais precisa identificar.

3.2 Conversão de variáveis

As 30 features preditoras já são numéricas contínuas e não exigem codificação, porque não há variáveis categóricas entre elas. A única variável categórica da base é o alvo, convertido para binário na etapa de limpeza (`src/data.py`).

O que essas variáveis exigem não é codificação, e sim padronização, pela diferença de escala descrita na seção 2.3.

3.3 Pipeline de pré-processamento

```
Pipeline
├── preprocessor
│   ├── SimpleImputer(strategy="median") # defensivo
│   └── StandardScaler()                # média 0, desvio padrão
1 └── estimator                          # modelo da vez
```

O escalonador fica dentro do pipeline por um motivo específico. Se fosse ajustado sobre a base completa antes da separação treino/teste, a média e o desvio usados na transformação carregariam informação do conjunto de teste, o que é vazamento de dados. O efeito é uma métrica otimista que não se sustenta em produção. Dentro do `Pipeline`, o escalonador é reajustado a cada partição da validação cruzada, usando apenas os dados de treino daquela partição.

Tabela 5 - Efeito da padronização sobre duas features de escalas extremas, no conjunto de treino


Feature	Média antes	Desvio antes	Média depois	Desvio depois
area_worst	890,57	582,35	0	1
fractal_dimension_se	0,00377	0,00263	0	1

Fonte: elaborado pelo autor.

O imputador de mediana é preventivo. A base atual não tem valores ausentes, mas o pipeline continua válido caso novos dados cheguem incompletos, e a mediana é robusta à assimetria observada na seção 2.3.

3.4 Análise de correlação

Figura 5 - Matriz de correlação entre as features



Fonte: elaborado pelo autor.

O mapa é dominado por correlações positivas, porque praticamente todas as features medem aspectos do tamanho e da irregularidade do mesmo núcleo celular. As poucas correlações negativas relevantes envolvem `fractal_dimension_mean`, que se comporta de forma inversa às medidas de tamanho.

Existem 21 pares de features com correlação acima de 0,9, e os extremos são quase perfeitos.

Tabela 6 - Pares de features com maior correlação linear

Par	Correlação
<code>radius_mean</code> × <code>perimeter_mean</code>	0,998
<code>radius_worst</code> × <code>perimeter_worst</code>	0,994
<code>radius_mean</code> × <code>area_mean</code>	0,987
<code>perimeter_mean</code> × <code>area_mean</code>	0,987
<code>radius_worst</code> × <code>area_worst</code>	0,984


Fonte: elaborado pelo autor.

Isso não é acaso estatístico, é geometria. Em uma forma aproximadamente circular, perímetro e área são funções diretas do raio. As três variáveis medem a mesma grandeza em unidades diferentes.

O efeito muda conforme a família de modelo. Na regressão logística, a capacidade preditiva não é prejudicada, mas os coeficientes individuais ficam instáveis, porque o peso se distribui de forma arbitrária entre variáveis redundantes. A regularização L2 (padrão do scikit-learn) atenua o problema ao distribuir o peso de maneira estável, mas interpretar cada coeficiente isolado exige cautela. No KNN, a mesma informação é contada várias vezes no cálculo da distância, o que dá peso excessivo à dimensão "tamanho do núcleo". Na Random Forest a predição é robusta, mas a importância nativa fica diluída, já que features redundantes dividem o crédito entre si e nenhuma parece tão relevante quanto de fato é. Esse é um dos motivos para complementar a análise com SHAP na seção 6.

Mesmo assim, nenhuma feature foi removida. Com 569 amostras e 30 features, a base não sofre de alta dimensionalidade, e a regularização já lida com a redundância. Seleção manual introduziria uma escolha arbitrária sem ganho esperado de desempenho. A multicolinearidade fica registrada para orientar a leitura dos coeficientes.

Figura 6 - Correlação de cada feature com o diagnóstico



Fonte: elaborado pelo autor.

Como o alvo é binário, a correlação de Pearson equivale ao coeficiente ponto-bisserial. O ranking reproduz quase exatamente o do d de Cohen, com `concave points_worst` (0,79), `perimeter_worst` (0,78) e `concave points_mean` (0,78) no topo. Duas métricas independentes chegando ao mesmo resultado reforçam o achado.

Nenhuma feature isolada chega perto de correlação 1 com o diagnóstico. Não existe atalho de variável única: a classificação depende da combinação de várias medidas.

3.5 Separação entre treino e teste

A divisão é de 80/20, com `stratify=y` e `random_state=42`.

Tabela 7 - Composição dos conjuntos após a divisão estratificada

Conjunto	Amostras	Benigno	Maligno	Proporção maligno
Treino	455	285	170	37,4%
Teste	114	72	42	36,8%
Base completa	569	357	212	37,3%

Fonte: elaborado pelo autor.

A estratificação mantém a proporção original nos dois conjuntos. Sem ela, a variação em uma base deste tamanho poderia tornar o conjunto de teste não representativo.

O conjunto de teste fica intocado até a avaliação final. Toda a comparação entre modelos é feita por validação cruzada estratificada de cinco partições dentro do conjunto de treino.

4 MODELAGEM

Código correspondente: `src/models.py`. Notebook: `notebooks/02_modeling_evaluation.ipynb`.

4.1 Modelos selecionados

Avaliei três técnicas com fundamentos distintos, para que a comparação fosse informativa e não apenas uma variação do mesmo viés.

Tabela 8 - Técnicas comparadas e justificativa de inclusão

Modelo	Como decide	Por que foi incluído
Regressão Logística	combinação linear das features passada por uma sigmoide	baseline interpretável, em que cada coeficiente indica quanto uma medida empurra a previsão, o que é essencial em contexto clínico

KNN	classe majoritária entre os k casos mais parecidos	não paramétrico, não assume forma da fronteira de decisão, e depende fortemente de escala, o que evidencia o efeito da padronização
Random Forest	votação de muitas árvores treinadas em amostras diferentes	captura relações não lineares e interações entre medidas, e fornece importância de variáveis nativa

Fonte: elaborado pelo autor.

Todos são Pipeline completos, com pré-processamento mais estimador, o que garante que a padronização seja reajustada dentro de cada partição da validação cruzada.

4.2 Escolha da métrica

O problema é clínico e assimétrico, porque os dois tipos de erro não custam a mesma coisa.

Tabela 9 - Custo clínico de cada tipo de erro

Erro	Significado clínico	Consequência
Falso negativo	tumor maligno classificado como benigno	paciente vai para casa sem tratamento e o diagnóstico atrasa
Falso positivo	tumor benigno classificado como maligno	exames adicionais, ansiedade, custo

Fonte: elaborado pelo autor.

Um falso negativo é incomparavelmente mais grave. Por isso a métrica prioritária é o recall da classe maligna, ou seja, a fração de tumores malignos que o modelo consegue capturar.

Duas ressalvas definem o protocolo adotado.

A acurácia não decide nada sozinha. Com 62,7% de casos benignos, um classificador que respondesse "benigno" sempre atingiria 62,7% de acurácia com recall zero. Ela é reportada, nunca isolada.

E o recall puro também não pode decidir a escolha do modelo. Otimizar apenas recall premiaria um classificador que chama quase tudo de maligno, com recall 100%, precisão baixa e nenhuma utilidade na triagem. Por isso a seleção do modelo usa F1, a média harmônica entre precisão e recall, e o recall é otimizado depois, pelo ajuste do limiar de decisão, tratado na seção 5.4.

4.3 Protocolo de validação

– Divisão estratificada 80/20, com o conjunto de teste intocado até a avaliação final

- Comparação entre modelos por validação cruzada estratificada de cinco partições dentro do treino
- Ajuste de hiperparâmetros por busca em grade pequena, otimizando F1 na mesma validação cruzada
- Semente fixa (`random_state=42`) em todas as etapas, para reprodutibilidade

Tabela 10 - Desempenho médio na validação cruzada, no conjunto de treino de 455 amostras

Modelo	Acurácia	Precisão	Recall	F1	AUC
Regressão Logística	0,974	0,977	0,953	0,964	0,996
KNN	0,965	0,988	0,918	0,951	0,987
Random Forest	0,960	0,958	0,935	0,946	0,988

Fonte: elaborado pelo autor.

A regressão logística lidera em F1 e recall, com desvio padrão baixo entre as partições. O resultado é estável, não fruto de uma partição favorável. O KNN tem a maior precisão (0,988) e o menor recall (0,918): é conservador, erra pouco quando afirma "maligno", mas deixa passar mais casos malignos. Para este problema, é a troca errada.

Vale comentar que um modelo linear vencer dois não lineares é informativo. Indica que, depois da padronização, as classes são quase linearmente separáveis no espaço das 30 features. Isso combina com a análise exploratória, que mostrou várias medidas fortemente deslocadas entre os grupos e nenhuma interação complexa aparente.

Tabela 11 - Melhores hiperparâmetros encontrados na busca em grade

Modelo	Melhores parâmetros	F1 na validação
Regressão Logística	$C = 1,0$	0,964
KNN	<code>n_neighbors = 3, weights = uniform</code>	0,963
Random Forest	<code>max_depth = 6, min_samples_leaf = 1, n_estimators = 200</code>	0,952

Fonte: elaborado pelo autor.

O ajuste altera pouco. A regressão logística já estava no C padrão, o KNN melhora ao reduzir k de 5 para 3, e a Random Forest melhora ao limitar a profundidade, sinal de leve sobreajuste. Nenhum ganho muda a ordem entre os modelos, o que reforça que a diferença vem da natureza de cada algoritmo e não de configuração.


O modelo escolhido é a **Regressão Logística**.

5 RESULTADOS E INTERPRETAÇÃO

5.1 Desempenho no conjunto de teste

Este é o primeiro e único uso dos 114 casos separados no início.

Figura 7 - Comparação dos três modelos no conjunto de teste



Fonte: elaborado pelo autor.

Tabela 12 - Desempenho dos três modelos nos 114 casos de teste

Modelo	Acurácia	Precisão	Recall	F1	AUC	Falsos negativos
Regressão Logística	0,965	0,975	0,929	0,951	0,996	3
Random Forest	0,965	1,000	0,905	0,950	0,995	4
KNN	0,939	0,973	0,857	0,911	0,983	6

Fonte: elaborado pelo autor.

O desempenho no teste confirma o da validação cruzada, sem queda relevante, então não há sinal de sobreajuste.

A Random Forest alcança precisão perfeita, sem nenhum falso positivo, mas com quatro falsos negativos. Trocar um falso positivo por um falso negativo é um mau negócio neste contexto: o primeiro custa um exame adicional, o segundo custa um diagnóstico perdido.

5.2 Matriz de confusão

Figura 8 - Matriz de confusão do modelo escolhido



Fonte: elaborado pelo autor.

O modelo escolhido acerta 110 dos 114 casos.

Tabela 13 - Leitura clínica de cada quadrante da matriz de confusão


Quadrante	Casos	Leitura clínica
Verdadeiros negativos	71	tumores benignos corretamente identificados
Verdadeiros positivos	39	tumores malignos corretamente identificados
Falsos positivos	1	uma paciente encaminhada a exames adicionais desnecessários
Falsos negativos	3	três tumores malignos classificados como benignos

Fonte: elaborado pelo autor.

Os três falsos negativos são o número que importa. Com recall de 0,929, o modelo deixa passar cerca de um em cada quatorze tumores malignos, o que é bom para um sistema de apoio e inaceitável para decisão autônoma.

5.3 Curvas ROC

Figura 9 - Curvas ROC dos três modelos




Fonte: elaborado pelo autor.

As três curvas ficam próximas do canto superior esquerdo, com AUC entre 0,983 e 0,996. A AUC mede a capacidade de ordenar corretamente os casos por risco, independentemente do limiar.

AUC de 0,996 combinada a recall de 0,929 no limiar padrão revela algo importante: o modelo separa bem as classes, e o que está mal calibrado é o corte.

5.4 Ajuste do limiar de decisão

Figura 10 - Efeito do limiar sobre as métricas



Fonte: elaborado pelo autor.

O limiar de 0,50 é apenas a convenção do `predict()`, não uma escolha clínica. Baixá-lo para 0,30 melhora todas as métricas ao mesmo tempo.

Tabela 14 - Efeito do limiar sobre as métricas e sobre os erros

Limiar	Recall	Precisão	F1	Falsos negativos	Falsos positivos
0,50 (padrão)	0,929	0,975	0,951	3	1
0,30	0,976	0,976	0,976	1	1

Fonte: elaborado pelo autor.

Em termos clínicos, duas pacientes a mais com tumor maligno seriam corretamente sinalizadas, sem aumento de exames desnecessários.

Duas ressalvas honestas sobre esse resultado. A primeira é que o conjunto de teste tem 114 casos, e uma diferença de dois falsos negativos é estatisticamente frágil e pode não se repetir em outra amostra. O limiar ideal deveria ser calibrado por validação cruzada no treino, e não escolhido observando o teste, senão o valor se ajusta ao próprio conjunto de avaliação.

A segunda é que a direção do ajuste é defensável independentemente do valor exato. Como o custo de um falso negativo é muito maior que o de um falso positivo, um limiar abaixo de 0,50 é a escolha racional para triagem, ainda que o ótimo preciso varie.

6 EXPLICABILIDADE

Código correspondente: `src/explain.py`.

Um sistema de apoio ao diagnóstico que não explica sua previsão não é utilizável na prática. O médico precisa poder concordar ou discordar com base no raciocínio, não apenas no número. Apliquei três técnicas complementares.


Tabela 15 - Técnicas de explicabilidade aplicadas e suas limitações

Técnica	O que responde	Limitação
Coefficientes	direção e força de cada medida no modelo linear	sofre com multicolinearidade, e só vale para modelos lineares
Importância por permutação	quanto o desempenho piora sem aquela medida	agnóstica ao modelo, mas apenas global
SHAP	quanto cada medida contribuiu para <i>esta</i> paciente	custo computacional maior

Fonte: elaborado pelo autor.

6.1 Coeficientes da regressão logística

Figura 11 - Maiores coeficientes da regressão logística



Fonte: elaborado pelo autor.

Tabela 16 - Cinco maiores coeficientes e as razões de chances correspondentes

Feature	Coeficiente	Razão de chances
texture_worst	+1,434	4,20
radius_se	+1,233	3,43
symmetry_worst	+1,061	2,89
concave points_mean	+0,953	2,59
concavity_worst	+0,911	2,49

Fonte: elaborado pelo autor.


Como as features estão padronizadas, os coeficientes são comparáveis entre si e a razão de chances tem leitura direta: um aumento de um desvio padrão em `texture_worst` multiplica por cerca de 4,2 a chance de o tumor ser maligno, mantidas as demais medidas constantes.

Um resultado aparentemente contraditório merece explicação. O maior coeficiente é `texture_worst`, e não `concave points_worst`, que liderava tanto o d de Cohen quanto a correlação com o alvo. A causa é a multicolinearidade documentada na seção 3.4: `concave points_worst` é altamente correlacionada com várias outras medidas de tamanho e contorno, e a regularização L2 distribui o peso entre todas elas, de modo que nenhuma recebe isoladamente um coeficiente grande. `texture_worst`, por ser relativamente independente das demais, carrega informação que nenhuma outra feature fornece, e por isso recebe peso alto.

A lição de interpretação é que coeficiente alto significa "informação única e útil ao modelo", não "medida mais importante clinicamente". Coeficientes isolados não bastam.

6.2 Importância por permutação

Figura 12 - Importância por permutação sobre o recall



Fonte: elaborado pelo autor.

Tabela 17 - Importância por permutação, medida sobre o recall da classe maligna

Feature	Queda média em recall	Desvio
texture_worst	0,0540	0,0212
concavity_worst	0,0421	0,0243
symmetry_worst	0,0278	0,0185
concave points_worst	0,0262	0,0188
radius_worst	0,0040	0,0205

Fonte: elaborado pelo autor.


A permutação mede o impacto real sobre o desempenho. Embaralhar `texture_worst` derruba o recall em 5,4 pontos percentuais. Depois das quatro primeiras features, a queda cai a praticamente zero, o que mostra que o modelo se apoia em poucas medidas e as demais são redundantes ou irrelevantes.

A métrica usada foi o recall, não a acurácia. A escolha importa, porque uma feature pode ser importante para a acurácia geral e irrelevante para detectar casos malignos, que é o objetivo aqui.

Uma ressalva: o desvio padrão é grande em relação à queda média, consequência dos 114 casos de teste. Os rankings devem ser lidos como indicativos, não como ordem precisa.

6.3 SHAP, visão global

Figura 13 - Valores SHAP para o conjunto de teste



Fonte: elaborado pelo autor.


Cada ponto é uma paciente. A posição horizontal mostra o quanto aquela medida empurrou a previsão para maligno, à direita, ou benigno, à esquerda, e a cor indica se o valor era alto, em vermelho, ou baixo, em azul.

O padrão é consistente e clinicamente coerente: para quase todas as features do topo, valores altos empurram para maligno. Núcleos maiores, mais irregulares e com contorno mais reentrante aumentam a probabilidade prevista de malignidade, exatamente o que a literatura médica descreve.

A exceção é `compactness_se`, cujo padrão se inverte. É efeito de compensação estatística entre variáveis correlacionadas, não achado clínico, e é o tipo de resultado que exige cautela antes de virar afirmação médica.

6.4 SHAP, um caso individual

Figura 14 - Decomposição SHAP de um tumor maligno não detectado



Fonte: elaborado pelo autor.

Este é um dos três tumores malignos classificados como benignos. A decomposição mostra exatamente por que o modelo errou: praticamente todas as medidas desta paciente estão abaixo da média da base, com `texture_worst` a $-0,83$ desvios padrão, `texture_mean` a $-0,85$, `symmetry_worst` a $-0,52$ e `area_worst` a $-0,13$. Cada uma empurrou a previsão para "benigno".

Em linguagem clínica, é um tumor maligno cujos núcleos celulares têm morfologia pouco característica. O modelo não cometeu um erro aleatório: viu um caso que genuinamente se parece com os benignos nas 30 medidas disponíveis.

Isso tem duas implicações diretas para o uso na prática. A primeira é que o modelo não substitui o médico, porque existem tumores malignos morfologicamente discretos e nenhum ajuste de hiperparâmetro resolve isso, já que a informação necessária não está nas features. A segunda é que a explicação é acionável: um médico que vê esta decomposição sabe que a previsão "benigno" se apoia em medidas fracas, sem nenhum sinal forte em contrário. Isso é qualitativamente diferente de um caso benigno com evidência robusta, e justifica exames complementares.

6.5 Convergência das três técnicas

As medidas `texture_worst`, `concavity_worst`, `symmetry_worst` e `concave points` aparecem no topo das três análises, obtidas por caminhos matematicamente independentes. A concordância aumenta a confiança de que o modelo aprendeu sinal real, e não artefato da partição de dados.

7 DISCUSSÃO CRÍTICA E USO NA PRÁTICA

7.1 O modelo pode ser usado na prática?

Sim, como ferramenta de apoio, não como decisor. O desempenho sustenta essa afirmação: recall de 0,929 e AUC de 0,996 no conjunto de teste, sem queda em relação à validação cruzada, com explicações coerentes com a morfologia celular descrita na literatura médica. Mas o mesmo conjunto de resultados delimita com precisão onde o uso autônomo seria irresponsável.

Três limitações são intransponíveis com esta base.

A primeira é a origem única e o volume pequeno. São 569 casos de uma única instituição, coletados sob um único protocolo. Nada garante que o desempenho se mantenha em outra população, com outro equipamento ou outro patologista extraindo as medidas. O conjunto de teste tem 114 casos, e a diferença entre três e um falso negativo, que sustenta a recomendação de ajuste do limiar, equivale a duas pacientes. É uma base pequena demais para decisões definitivas.

A segunda é que o sistema não parte de dados crus. As 30 features já são o resultado de uma etapa anterior de análise por um especialista, que examinou a imagem da punção e mediu os núcleos celulares. O modelo automatiza o julgamento a partir das medidas, não a extração das medidas. Na prática, isso significa que ele não reduz a carga de trabalho especializada, apenas apoia a decisão final. A entrega complementar deste projeto, com CNN sobre ultrassons, ataca justamente essa limitação.

A terceira é que existem tumores malignos morfologicamente discretos. A análise SHAP do caso 16 do conjunto de teste mostrou um tumor maligno cujas medidas estão quase todas abaixo da média da base. O modelo não errou por acaso: viu um caso que genuinamente se parece com os benignos nas variáveis disponíveis. Nenhum ajuste de hiperparâmetro resolve isso, porque a informação necessária não está nos dados.

7.2 Como o modelo seria usado

São três cenários concretos, em ordem crescente de exigência.

Tabela 18 - Cenários de uso do modelo no fluxo clínico

Cenário	Como funcionaria	Por que agrega valor
Priorização de fila	ordenar os casos pendentes pela probabilidade prevista de malignidade	casos de alto risco chegam antes ao especialista, e ninguém é excluído da análise
Segunda opinião	exibir previsão, probabilidade e explicação SHAP junto ao laudo em elaboração	oferece um contraponto estruturado antes da assinatura
Sinalização de discordância	alertar quando modelo e laudo preliminar divergem	atua como rede de segurança contra desatenção, não como substituto do julgamento

Fonte: elaborado pelo autor.

Em todos, o laudo é assinado por um médico. O sistema nunca emite diagnóstico, nunca dispensa uma paciente e nunca é a última etapa do fluxo.

7.3 O limiar de decisão é uma escolha clínica, não técnica

O limiar padrão de 0,50 vem da convenção do `predict()`, não de nenhuma consideração médica. Este projeto mostrou que 0,30 reduz os falsos negativos de três para um sem aumentar os falsos positivos, mas o ponto mais importante é outro: quem deve escolher esse valor é a instituição de saúde, não o cientista de dados, porque a escolha traduz uma decisão de política clínica sobre quantos exames adicionais se aceita realizar para não deixar um tumor maligno passar.

O que a análise técnica entrega é a curva de compromisso da seção 5.4, que torna essa decisão informada em vez de arbitrária.

7.4 Riscos de implantação

Um sistema que acerta 96,5% das vezes pode induzir excesso de confiança e levar o profissional a aceitar previsões sem revisar, que é justamente o efeito que a explicabilidade busca combater ao expor o raciocínio por trás de cada resposta.

Há também o risco de degradação silenciosa. Mudanças de equipamento, protocolo ou população deslocam a distribuição dos dados sem gerar nenhum erro visível. Uso em produção exigiria monitoramento contínuo das métricas e recalibração periódica.

Outro risco é a interpretação equivocada da importância das variáveis. Como mostrei na seção 6.1, `texture_worst` tem o maior coeficiente por ser pouco correlacionada com as

demais, não por ser clinicamente mais relevante. Comunicar isso como "a textura é o que mais importa no diagnóstico" seria um erro grave de tradução entre estatística e medicina.

Por fim, há responsabilidade legal e ética. Um sistema de apoio ao diagnóstico opera sobre dados sensíveis de saúde e influencia decisões médicas. Implantação real exigiria conformidade com a LGPD, rastreabilidade das previsões e definição explícita de responsabilidade sobre o desfecho.

7.5 Próximos passos técnicos

1. Validação externa em base de outra instituição, o teste decisivo que esta base não permite.
2. Calibração do limiar por validação cruzada no treino, em vez de observação do conjunto de teste, eliminando o risco de ajuste ao próprio conjunto de avaliação.
3. Calibração de probabilidade, por Platt scaling ou regressão isotônica, para que o valor previsto possa ser lido como risco real e não apenas como ordenação.
4. Diagnóstico a partir de imagem com redes neurais convolucionais, removendo a dependência da extração manual de medidas, que é a entrega complementar deste desafio.

8 ENTREGA COMPLEMENTAR: DIAGNÓSTICO POR IMAGEM COM CNN

Código correspondente: `src/vision/`. Notebook: `notebooks/03_vision_cnn.ipynb`. Execução: `python scripts/run_vision.py`.

A seção 7.1 apontou uma limitação central do pipeline tabular: ele não parte de dados crus. As 30 features do Wisconsin já são resultado de um especialista ter examinado a imagem e medido os núcleos celulares. Esta entrega ataca exatamente essa limitação, classificando a partir do pixel.

8.1 A base BUSI

A base é a BUSI, Breast Ultrasound Images (AL-DHABYANI et al., 2020), sob licença CC BY 4.0. São 780 imagens de ultrassom mamário de 600 pacientes, em três classes. O enunciado do desafio autoriza explicitamente imagens de mamografia ou ultrassom.


Tabela 19 - Distribuição das classes na base BUSI

Classe	Imagens	Proporção
--------	---------	-----------

benign	437	56,0%
malignant	210	26,9%
normal	133	17,1%


Fonte: elaborado pelo autor.

Figura 15 - Distribuição das imagens por classe



Fonte: elaborado pelo autor.

Figura 16 - Exemplos de imagens de cada classe



Fonte: elaborado pelo autor.

Uma armadilha do dataset valeu registro. O BUSI distribui as máscaras de segmentação (*_mask.png) na mesma pasta das imagens, num total de 798 arquivos. O carregador do Keras lê tudo o que encontra no diretório: mantidas ali, as máscaras entrariam como se fossem exames, dobrando o conjunto com imagens binárias que não existem clinicamente e inflando as métricas sem sentido. O carregamento detecta máscaras e interrompe com instrução explícita, em vez de treinar sobre um conjunto silenciosamente contaminado.

8.2 Duplicatas, o problema que precedeu qualquer métrica

Antes de reportar desempenho foi preciso resolver um defeito da base. O BUSI contém vários quadros do mesmo exame, praticamente indistinguíveis entre si. Uma auditoria por *hash* perceptual, que compara miniaturas em tons de cinza e tolera diferenças de compressão, encontrou o seguinte.

Tabela 20 - Resultado da auditoria de imagens duplicadas na base BUSI

Verificação	Resultado
Imagens	780
Grupos de imagens distintas	668
Grupos com mais de um quadro	95
Imagens redundantes	112
Grupos com rótulos contraditórios	7

Fonte: elaborado pelo autor.

Dois achados exigem comentário.

O primeiro é que 112 das 780 imagens são repetições de exames já presentes na base. Distribuídas ao acaso, 62 pares caíam em partições diferentes, e a rede era avaliada em imagens que já tinha visto no treino. É vazamento de dados, exatamente o problema que o pipeline tabular evita ao manter o `StandardScaler` dentro do `Pipeline`.

O segundo é que sete grupos têm rótulos contraditórios: imagens praticamente idênticas catalogadas com diagnósticos diferentes, incluindo um par byte a byte igual que aparece como `benign` (433) e como `malignant` (145). Não há como decidir qual rótulo está correto sem acesso ao laudo original, então mantive os casos e registrei o problema. Eles representam um limite de qualidade da base, não do modelo.

A correção foi tratar cada grupo como uma unidade indivisível na partição. O `StratifiedGroupKFold` atende às duas exigências ao mesmo tempo: preserva a proporção das classes e nunca separa um grupo.

8.3 Protocolo

- Divisão estratificada e agrupada, com 556 imagens de treino, 112 de validação e 112 de teste, sem nenhum grupo de quadros repetidos dividido entre conjuntos
- Proporção de casos malignos de 27,0% no treino, 26,8% na validação e 26,8% no teste, contra 26,9% na base completa
- Imagens redimensionadas para 224×224, entrada padrão das redes pré-treinadas
- Pesos de classe inversamente proporcionais à frequência, para que a rede não aprenda a favorecer a classe majoritária
- Aumento de dados apenas geométrico: espelhamento, rotação leve, zoom e translação. Distorções de cor seriam arriscadas, porque em imagem médica a intensidade carrega informação diagnóstica
- Parada antecipada monitorando a perda de validação, com restauração dos melhores pesos
- Execução determinística, com sementes fixas e `enable_op_determinism()`. Sem isso, cada execução produzia métricas diferentes, porque inicialização de pesos, embaralhamento e aumento de dados usam geradores próprios

8.4 Arquiteturas comparadas

Tabela 21 - Arquiteturas avaliadas na entrega complementar

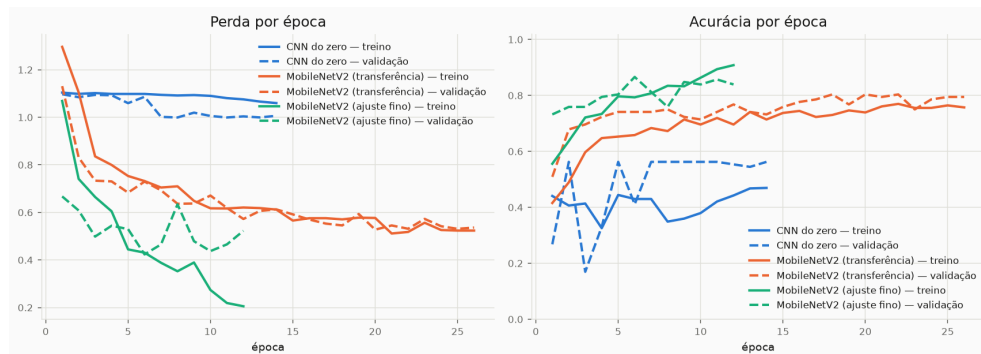
Modelo	Parâmetros	Ideia
CNN do zero	110 mil	três blocos convolucionais treinados apenas com as 556 imagens disponíveis
MobileNetV2 (transferência)	2,26 milhões	base pré-treinada na ImageNet, congelada, com cabeça de classificação nova
MobileNetV2 (ajuste fino)	2,26 milhões	segunda etapa, em que as 60 camadas finais da base são liberadas com taxa de aprendizado dez vezes menor

Fonte: elaborado pelo autor.

O ajuste fino só faz sentido depois que a cabeça converge com a base congelada. Aplicado a pesos aleatórios, os gradientes iniciais destruiriam as features pré-treinadas. Três cuidados tornam a etapa segura: apenas as camadas finais são liberadas, já que as primeiras detectam bordas e texturas úteis em qualquer imagem; a taxa de aprendizado cai de $1e-3$ para $1e-4$; e as camadas de normalização em lote permanecem congeladas, porque atualizar suas estatísticas com lotes pequenos degradaria a normalização aprendida em milhões de imagens.

8.5 Resultados

Figura 17 - Curvas de treino das três arquiteturas



Fonte: elaborado pelo autor.

Tabela 22 - Desempenho das três arquiteturas nas 112 imagens de teste

Modelo	Épo cas	Melhor época	Acur ácia	F1 mac ro	Recall maligno	Precisão maligno	Não detectados	Te mpo
MobileNetV2 (ajuste fino)	12	6	0,83 9	0,82 1	0,900	0,771	3 de 30	78 s
MobileNetV2 (transferência)	26	20	0,75 9	0,75 1	0,767	0,622	7 de 30	140 s
CNN do zero	14	8	0,56 3	0,24 0	0,000	0,000	30 de 30	97 s

Fonte: elaborado pelo autor.


A CNN treinada do zero não aprendeu a tarefa. Com 56,3% de acurácia, ela não detectou nenhum dos 30 casos malignos: aprendeu a responder "benigno", que é a resposta mais frequente. É a demonstração prática do que a seção 2.2 já afirmava sobre a acurácia como métrica isolada, porque um modelo pode exibir mais de metade de acerto e ter valor clínico zero. As curvas confirmam, com a perda de validação mal se movendo ao longo de 14 épocas. Com 556 imagens, não há dados suficientes para aprender filtros visuais a partir do zero.

A transferência de aprendizado é o que torna a tarefa viável, e o ajuste fino é o que a torna razoável. Liberar as camadas finais elevou o recall da classe maligna de 0,767 para 0,900, reduzindo de sete para três os casos não detectados, e ainda assim melhorou a precisão. As features da ImageNet servem de ponto de partida, mas texturas de ultrassom não se parecem com fotografias naturais, e adaptá-las é o que faz diferença.

Duas notas de método valem mais que os números. Uma tentativa conservadora de ajuste fino, com 40 camadas e taxa $1e-5$, não moveu os pesos e parou na primeira época, o que mostra que a configuração precisa ser testada e não presumida. E a primeira

implementação continha um defeito silencioso: a busca pela base pré-treinada usava `isinstance(camada, Model)`, e a camada de aumento de dados é um `Sequential`, que também é um `Model`, de modo que o código liberava o bloco de aumento em vez da `MobileNetV2`. Nada acusava erro. Um teste exigindo que as camadas liberadas pertençam à base expôs o problema.

Figura 18 - Matriz de confusão do modelo de imagem



Fonte: elaborado pelo autor.

A matriz do modelo escolhido detalha os erros nas 112 imagens de teste:

- 27 dos 30 casos malignos corretamente identificados
- três malignos classificados como benignos, os erros de maior custo, e nenhum deles foi confundido com tecido normal
- oito benignos classificados como malignos, que no fluxo clínico significam exames adicionais

- sete imagens normais classificadas como benignas, erro sem consequência clínica relevante


8.6 Explicabilidade, onde a rede olhou

Código correspondente: `src/vision/explain.py`.

O pipeline tabular responde "por que esta paciente?" com SHAP, decompondo a previsão em contribuições por medida. Em imagem não existem medidas, existem pixels, e a pergunta equivalente é onde a rede olhou. O Grad-CAM responde isso: toma o último mapa de ativação convolucional, mede pelo gradiente o quanto cada canal influencia a pontuação da classe, e soma os canais ponderados por essa influência.

A leitura correta exige uma ressalva. O mapa mostra onde, não por quê. Ele não afirma que a rede reconheceu uma margem espiculada, apenas que aquela região pesou na decisão. Ainda assim, é o que permite a um médico discordar de forma fundamentada, porque um mapa centrado fora da lesão denuncia uma previsão correta pelo motivo errado.

Figura 19 - Grad-CAM em casos malignos detectados




Fonte: elaborado pelo autor.

Nos casos detectados corretamente, o calor se concentra sobre a lesão. No primeiro, a massa hipoeoica central é exatamente a região que sustenta a previsão, com 0,95 de confiança. Nos outros dois, a atenção cobre a área da lesão e sua vizinhança imediata. O

modelo está olhando para o lugar certo, o que não era garantido, e é justamente o que a explicabilidade existe para verificar.

Figura 20 - Grad-CAM em casos malignos não detectados



Fonte: elaborado pelo autor.

Nos casos que escaparam, o padrão se inverte de forma reveladora: a lesão permanece fria e o calor migra para o canto inferior direito, uma região de sombra acústica sem relevância diagnóstica. O modelo não avaliou mal a lesão, ele não a considerou. A confiança na classe maligna despenca para 0,01 e 0,03.

Duas observações adicionais nessas imagens. Elas trazem anotações gravadas em pixel, como marcadores de medição em cruz, linha pontilhada e etiqueta de posição, feitas pelo profissional que já identificou a lesão suspeita. Essas marcas carregam informação do diagnóstico, e uma rede que aprendesse a reconhecê-las teria desempenho alto e valor clínico nulo, porque em um exame novo elas não existem. Os mapas mostram que, ao menos nestes casos, a atenção não se fixa nelas. E as duas primeiras colunas são o mesmo exame, em quadros quase idênticos. Aparecem juntas no conjunto de teste porque o agrupamento descrito na seção 8.2 as manteve inseparáveis. Antes da correção, teriam sido distribuídas entre treino e teste.

Um defeito encontrado durante esta etapa merece registro, porque é sutil e silencioso. A normalização da MobileNetV2 era aplicada como chamada de função durante a construção

do modelo. Uma função aplicada ao tensor é absorvida pelo grafo e não aparece na lista de camadas, então o Grad-CAM, que percorre as camadas, pulava a normalização e alimentava a rede com pixels de 0 a 255 onde ela espera valores de -1 a 1 . Os mapas resultantes eram ruído com aparência plausível, e as probabilidades exibidas ficavam abaixo de um terço em um problema de três classes, o que é matematicamente impossível para a classe prevista. A normalização passou a ser declarada como camada, e um teste agora exige que percorrer as camadas reproduza exatamente a saída de `predict`.

8.7 Comparação honesta entre as duas entregas

Tabela 23 - Comparação entre a entrega tabular e a entrega por imagem

Aspecto	Wisconsin (tabular)	BUSI (imagem)
Entrada	30 medidas extraídas por especialista	pixels do exame
Recall da classe maligna	0,929	0,900
Amostras	569	780 (668 exames distintos)
Dependência humana prévia	alta, exige medição manual	nenhuma
Explicabilidade	coeficientes, permutação e SHAP	Grad-CAM sobre a imagem

Fonte: elaborado pelo autor.

O modelo tabular ainda leva vantagem nas métricas, mas resolve um problema mais fácil, porque recebe medidas que um profissional já extraiu. O modelo de imagem opera sobre o dado bruto, sem etapa manual anterior, o que o deixa mais próximo de um sistema de triagem real e mais longe de estar pronto.

Com recall de 0,900, um em cada dez tumores malignos ainda escaparia. É um resultado adequado a uma demonstração de viabilidade acadêmica e insuficiente para uso clínico, ainda que como triagem. Os caminhos conhecidos para melhorar, como mais dados, resolução maior, validação cruzada em vez de partição única, ajuste de limiar por classe e remoção das anotações gravadas nas imagens, estão fora do escopo desta fase. Nenhum deles contradiz a conclusão da seção 7: o médico continua com a palavra final.

9 REPRODUTIBILIDADE E EXECUÇÃO

O repositório do projeto está em <https://github.com/gustavofks/ML-breast-cancer>. O código está organizado em `src/`, dividido em 11 módulos que cobrem configuração, dados, pré-processamento, análise exploratória, modelos, avaliação, explicabilidade, gráficos, geração de relatório e o pacote de visão computacional. Dois scripts executam cada pipeline

de ponta a ponta, e 86 testes automatizados cobrem desde o carregamento dos dados até a geração do relatório.

A semente aleatória é fixa em todas as etapas e as versões das dependências estão travadas. Executar o pipeline duas vezes produz o mesmo arquivo de métricas, e a execução em container Linux produz o mesmo arquivo que a execução local em Windows, verificado campo a campo. Nenhum número deste relatório foi escrito manualmente: todos provêm de `results/metrics.json` e `results/metrics_vision.json`.

O clone já traz o dataset tabular, as figuras, as métricas e o relatório visual gerados, então o resultado pode ser conferido sem executar nada. Basta abrir `results/reports/index.html` no navegador, porque a página é estática e não depende de servidor nem de rede.

A execução com Docker dispensa qualquer instalação prévia de Python:

```
git clone https://github.com/gustavofks/ML-breast-cancer.git
cd ML-breast-cancer
docker build -t ml-breast-cancer .
docker run --rm -v "$(pwd)/results:/app/results" ml-breast-cancer
```

O container executa o pipeline completo e grava as figuras, o `metrics.json` e o `index.html` no `results/` montado. A execução local requer Python 3.11:

```
py -3.11 -m venv .venv
.venv\Scripts\activate
pip install -r requirements.txt
python scripts/run_wisconsin.py
```

A entrega complementar com imagens tem dependências próprias, instaladas à parte para manter a instalação principal leve, e precisa da base BUSI, que não é versionada por causa do tamanho:

```
pip install -r requirements-vision.txt
python scripts/run_vision.py
```

Com Docker, ela é um estágio separado do mesmo `Dockerfile`:

```
docker build --target vision -t ml-breast-cancer:vision .
```

A suíte de testes é executada com `pytest`. São 86 testes cobrindo carregamento, pré-processamento, modelagem, avaliação, explicabilidade, o pipeline de imagem e a geração do relatório.

Uma nota sobre o SHAP encerra a seção. A biblioteca depende do `numba`, cuja DLL compilada é bloqueada por algumas políticas de segurança do Windows, como App Control e

Smart App Control. O pipeline detecta a ausência e continua, mantendo coeficientes e importância por permutação. As figuras SHAP versionadas em `results/figures/` permanecem válidas, e dentro do container Linux elas são regeneradas normalmente.

10 CONSIDERAÇÕES FINAIS

O projeto entrega um classificador com desempenho alto, estável e explicável, construído sobre um protocolo metodológico defensável: sem vazamento de dados, com separação clara entre treino e teste, métrica escolhida pelo custo clínico do erro e três técnicas independentes de explicabilidade convergindo nos mesmos achados.

Seu valor prático não está em substituir o julgamento médico, e sim em tornar esse julgamento mais rápido e mais informado, priorizando filas, oferecendo segunda opinião estruturada e sinalizando divergências. O caso do tumor maligno não detectado, dissecado pela análise SHAP, é o argumento mais concreto a favor dessa posição: existem limites que o dado disponível não permite ultrapassar, e reconhecê-los faz parte de entregar o sistema de forma responsável.

REFERÊNCIAS

AL-DHABYANI, W.; GOMAA, M.; KHALED, H.; FAHMY, A. Dataset of breast ultrasound images. **Data in Brief**, 2020.

LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. In: **Advances in Neural Information Processing Systems (NIPS)**, 2017.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, 2011.

SANDLER, M.; HOWARD, A.; ZHU, M.; ZHMOGINOV, A.; CHEN, L.-C. MobileNetV2: inverted residuals and linear bottlenecks. In: **IEEE Conference on Computer Vision and Pattern Recognition (CVPR)**, 2018.

SELVARAJU, R. R. et al. Grad-CAM: visual explanations from deep networks via gradient-based localization. In: **IEEE International Conference on Computer Vision (ICCV)**, 2017.

UCI MACHINE LEARNING REPOSITORY. **Breast Cancer Wisconsin (Diagnostic) Data Set**. Disponível em: <https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data>. Acesso em: 2026.